不同来源金融文本信息含量的异质性分析——基于混合式文本情绪测度方法

范小云，王业东，王道平，郭文璇，胡煊翊

管理世界，*2022*

解读人：赵伟皓

武汉大学金融系

2026.04.05

研究问题

不同来源的金融文本（正式媒体新闻、非正式股吧发帖）的信息含量存在怎样的异质性？

1. 如何优化中文金融文本的情绪测度方法，以准确提取文本中的软信息?
   - 手工分类的词典法 + 机器学习
2. 正式新闻文本、散户股吧文本分别对宏观经济、股票市场的预测能力有何不同?
   - 这种差异的作用机制是什么?
   - 宏观层面中介变量：消费者信心、投资规模
   - 市场层面中介变量：股吧情绪

研究动机

该问题在领域的重要性：

1. 不同来源的文本所包含什么信息以及能用来解决的问题会直接影响决策：
   - 官方新闻、股吧发帖、自媒体和社交动态等，时效性远强于传统的 GDP、CPI 等硬数据。
   - 如果没有一个确定的研究结论，大家对软信息的使用完全是盲目的，可能导致错误决策。
   - 宏观层面：传统的硬数据发布滞后，而新闻情绪或许可以预测宏观指标；
2. A 股是散户主导的市场，投机性强、市场波动大，软信息的价值逻辑与其他市场不同。
   - 市场层面：极端化情绪会直接推高市场波动（股吧情绪的预测力）

现有研究的局限性：

1. 过往文献未系统对比两类文本的信息含量差异：
   - 要么仅研究媒体新闻的影响，要么仅分析社交媒体发帖的作用；
   - 忽略了正式 / 非正式文本在语言特征和信息属性上的区别。
2. 中文语境下的测度方法局限：
   - 中文金融情绪测度缺乏专属词典，通用词典适配性差；
   - 词典法忽略上下文语义，机器学习容易过拟合、可复制性弱，无成熟的中文金融文本情绪融合测度方法。
3. 国内基于中文金融文本（尤其是新闻）的信息含量研究尚处起步阶段，缺乏针对中国市场的大样本实证证据。

研究贡献

1. **文本情绪分析方法的文献**
   Prior: 中文通用词典脱离金融领域语义；专用词典词汇覆盖不足，词典法虽可重复性高，但忽略词语的上下文特征（徐琳宏等，2008；姜富伟等，2021）；
   Prior：机器学习依赖人工标注的文档库，结果主观性强、可复制性差（钱宇等，2020）。
   Extend: 为新闻、股吧分别构建了基于 N-gram 的专属词典；将词典与机器学习的语义能力结合。

2. **使用不同来源金融文本的文献**
   Prior: 大多仅关注单一文本情绪的影响，缺少对宏观经济预测的检验（李等，2019）；
   Extend: 系统对比两类文本的信息含量异质性，将新闻按主题分类、同时检验宏观 / 股市的预测能力。

研究假设

1. H1：文本情绪对宏观经济指标的预测能力：
   - H1a：积极的新闻情绪能够正向预测宏观经济指标；（如消费、产出、物价等）
   - H1b：积极的股吧情绪不能正向预测宏观经济指标；
2. H2：文本情绪对股票市场的预测能力：
   - H2a：积极的新闻情绪能够正向预测中国股票市场收益；
   - H2b：积极的股吧情绪能够正向预测中国股票市场收益；

样本选择

1. 新闻与股吧样本时间区间对齐（2011.1 2019.12）
2. 报纸（新闻）：
   - 32 家国内财经类、综合类报纸，175 万条新闻样本；
   - 按内容分类：证券类、经济类、范经济类、综合类；
3. 东方财富网股吧市场层面：
   - “上证指数吧”中的 489 万条帖子；
   - 上证综合指数用于衡量股票整体走势。
4. 个股层面：
   - 1769 家在上交所上市的公司，约 1998 万条帖子。

中文词典构建

现有词典（大连理工 DLUT；卞等，2019；姜富伟等，2021）：

表 2 现有中文情绪词典比较

词典	词汇数量		特有词汇	
	积极词	消极词	数量	比例
DLUT	11229	10783	18289	0.831
Bian	1107	1488	491	0.189
Jiang	3338	5890	4448	0.482

表 4 现有词典对本文构建词典的覆盖程度比较

词典	新闻覆盖词汇		股吧覆盖词汇	
	数量	比例	数量	比例
DLUT	341	0.099	426	0.112
Bian	464	0.135	402	0.106
Jiang	664	0.194	648	0.171

Pos = 积极词个数/文本总词数

Neg = 消极词个数/文本总词数

$$\text{Sentiment} = \frac{\text{Pos} - \text{Neg}}{\text{Pos} + \text{Neg}} \tag{1}$$

本文情绪词典 NSD、ESD

N-gram：由 N 个单词组成的结合，各单词具有先后顺序

- 以往在构建词典时仅考虑一元词汇而忽略了上下文（导致情绪判断偏误）。
- 本文随机选取新闻和帖子各 20000 条，人工判断语料情绪，并给出理由。
- NSD 为新闻情绪词典，ESD 为股吧情绪词典。

表 3 文本情绪手工分类实例

内容	情绪	原因	类型
不必担心杠杆率短期波动	1	高增长、质量提升	新闻
比特币疯涨背后暗藏危机	−1	暗藏、危机	新闻
现代保险服务业如何服务社会治理新常态	0		新闻
都别急，明天探底回升	1	探底回升	股吧
下午应该会拉起来别慌	1	拉起来、别慌	股吧
赶快跑，大盘反弹到位了，下周要跌	−1	赶快跑、要跌	股吧

样本内外情绪准确性判断

表 5 基于词典法的情绪分析准确率

	新闻	股吧
DLUT	0.452	0.433
Bian	0.589	0.512
Jiang	0.606	0.598
NSD/ESD	0.870	0.768
Jiang+NSD/ESD	0.785	0.881
DLUT+NSD/ESD	0.750	0.697
Bian+NSD/ESD	0.808	0.751

表 6 基于词典法的样本外情绪分析准确率

	新闻	股吧
DLUT	0.456	0.334
Bian	0.541	0.323
Jiang	0.524	0.398
NSD/ESD	0.774	0.739
Jiang+NSD/ESD	0.711	0.750
DLUT+NSD/ESD	0.632	0.651
Bian+NSD/ESD	0.723	0.671

- 现有三个词典的情绪判断均不理想，本文 NSD/ESD 词典大大提升精度（样本外稳健）；
- **NSD 词典用于判断新闻情绪，ESD + Jiang 用于判读股吧帖子情绪。**

混合式文本情绪测度

1. 把词典法得到的“Pos、Neg 数量”，作为两个新特征，加入到 ML 的词频特征向量中；
2. ML 算法：朴素贝叶斯、随机森林、逻辑回归、GBDT、AdaBoost，最终选择 GBDT。

表 7 机器学习方法和混合式方法的情绪分析准确率

	新闻				股吧			
	训练集		测试集		训练集		测试集	
	机器学习	混合式	机器学习	混合式	机器学习	混合式	机器学习	混合式
NB	0.926	0.947	0.804	0.866	0.923	0.948	0.776	0.853
RF	0.993	0.994	0.749	0.906	0.981	0.993	0.687	0.913
LR	0.989	0.809	0.853	0.894	0.944	0.809	0.782	0.831
GBDT	0.788	0.986	0.712	0.929	0.687	0.956	0.612	0.927
AdaBoost	0.684	0.937	0.627	0.919	0.633	0.919	0.555	0.925

新闻情绪（NSH）：按公式计算单篇新闻的情绪，取值范围 [-1,1]，再按报纸类别汇总；
股吧情绪（ESH）：同样计算单条帖子的情绪，对市场层面构建了隔夜股吧情绪。

H1a：积极的新闻情绪能够正向预测宏观经济指标

$$\text{Macro}_t = \alpha_1 + \alpha_2 S_{i,t-1} + X_{t-1} + \epsilon \tag{2}$$

表 9 不同类别的新闻文本情绪预测宏观经济指标

	(1)	(2)	(3)	(4)
	经济类	证券类	泛经济类	综合类
Panel A：不同类别的新闻文本情绪预测消费				
L.*NSH*	0.0169***	0.0218***	0.0069**	0.0160***
	(0.0028)	(0.0038)	(0.0031)	(0.0028)
L.*home*	−0.0876***	−0.0650*	−0.0883***	−0.0955***
	(0.0282)	(0.0334)	(0.0241)	(0.0238)
L.*income*	0.9434***	0.9624***	1.0498***	1.0023***
	(0.0335)	(0.0362)	(0.0239)	(0.0251)
L.*Y1*	0.0144	0.0137	0.0144*	0.0157**
	(0.0093)	(0.0110)	(0.0080)	(0.0079)

Panel D：不同类别的新闻文本情绪预测实际利率

实际利率	(1)	(2)	(3)	(4)
	经济类	证券类	泛经济类	综合类
L.*NSH*	0.0774***	0.1180***	0.0651**	0.1080***
	(0.0212)	(0.0309)	(0.0269)	(0.0235)
L.*stkr*	1.8392***	1.3085	1.8239***	1.7991***
	(0.6709)	(0.8081)	(0.5662)	(0.5620)
L.*exp*	−1.7064***	−1.6541***	−1.8407***	−1.7260***
	(0.2708)	(0.3195)	(0.2245)	(0.2248)
L.*Kqindex*	−0.0850***	−0.0797***	−0.0831***	−0.0843***
	(0.0099)	(0.0116)	(0.0083)	(0.0083)

新闻媒体是社会大众了解经济状况的重要信息来源，是影响消费、投资决策的重要因素。

新闻文本预测宏观指标机制结果

$$\mathrm{M}_{t-1} = \beta_1 + \beta_2 S_{i,t-1} + X_{t-1} + \epsilon \tag{3}$$

$$\mathrm{Macro}_t = \gamma_1 + \gamma_2 S_{i,t-1} + \gamma_3 \mathrm{M}_{t-1} + X_{t-1} + \epsilon \tag{4}$$

Panel A：新闻文本情绪预测消费的机制分析

消费	经济类		证券类		泛经济类		综合类	
	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
	L_confident	*Consumption*	*L_confident*	*Consumption*	*L_confident*	*Consumption*	*L_confident*	*Consumption*
L_NSH	0.7347***	0.0132***	0.6543***	0.0185***	0.4407***	0.0043	0.5125***	0.0131***
	(0.1123)	(0.0029)	(0.1509)	(0.0037)	(0.1221)	(0.0030)	(0.1135)	(0.0028)
L_confident		0.0050***		0.0051***		0.0059***		0.0056***
		(0.0009)		(0.0011)		(0.0008)		(0.0007)
Control	Yes	Yes	Yes	Yes	Yes	Yes	Yes	Yes
adj. R^2	0.742	0.716	0.739	0.720	0.732	0.710	0.733	0.715
N	749	749	535	535	1070	1070	1070	1070

- 以消费者信心为中介变量，对新闻情绪影响消费、产出和通胀率进行机制检验；
  - 消费者信心指数是国家统计局发布的反映消费者信心强弱的指标。
  - 新闻文本对未来消费、通胀、产出的影响，是通过影响消费者信心来发挥机制的。

新闻文本预测宏观指标机制结果

Panel D：新闻文本情绪预测实际利率的机制分析

实际利率	经济类		证券类		泛经济类		综合类	
	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)
	L.*Invest*	*Bondrate*1	L.*Invest*	*Bondrate*1	L.*Invest*	*Bondrate*1	L.*Invest*	*Bondrate*1
L.*NSH*	0.0654***	−0.1224***	0.0755***	−0.0912***	0.0516***	−0.0656***	0.0650***	−0.0604***
	(0.0034)	(0.0226)	(0.0051)	(0.0326)	(0.0050)	(0.0249)	(0.0042)	(0.0231)
L.*Invest*		3.0558***		2.7715***		2.5328***		2.5911***
		(0.1987)		(0.2328)		(0.1455)		(0.1539)
Control	Yes	Yes	Yes	Yes	Yes	Yes	Yes	Yes
adj. R^2	0.401	0.349	0.365	0.326	0.188	0.323	0.274	0.323
N	749	749	535	535	1070	1070	1070	1070

- 以私人投资规模为中介变量，对新闻情绪影响实际利率进行机制检验；
  - 私人投资规模：全社会固定资产投资减去其中来源于国家预算内资金的部分（刘溶沧、马拴友，2001）；
  - 市场在积极的新闻文本情绪的驱动下，对未来普遍抱有乐观预期，企业投资意愿增加，投资规模扩大，带来实际利率上涨。

H1b：股吧情绪无法预测宏观经济指标

宏观指标对股吧文本情绪的回归系数均不显著，仅通胀率的回归系数在 10% 的水平上显著。

表 11 股吧情绪预测宏观经济

	(1)	(2)	(3)	(4)
	消费	通货膨胀率	GDP	实际利率
L.*ESH*	0.0062	0.0246*	0.0006	−0.0236
	(0.0045)	(0.0145)	(0.0022)	(0.0220)
L.*home*	−0.0772			
	(0.0772)			
L.*Income*	1.0190***			
	(0.0802)			
L.*Y1*	0.0107			
	(0.0256)			

积极的股吧情绪不能正向预测消费、产出、物价和实际利率等宏观经济指标。

- 中国股票市场尚不成熟，股吧用户以个体投资者为主，投机氛围比较重，对经济基本面的反映有限。

H2 结果与机制检验

$$R_t = \alpha_1 + \sum_i \alpha_{2i} S_{t-i} + \sum_j \alpha_{3j} R_{t-j} + \sum_k \alpha_{4k} R_{t-k}^2 + X_{t-1} + \varepsilon \tag{5}$$

- S_t 是基于股票论坛或新闻文本的每日投资者情绪，对于股吧文本测度时间范围为第 t 天 15:30 到第 t+1 天的 9:30，为隔夜投资者情绪。
- **H2a：证券类和经济类新闻情绪**能够正向预测未来收益率;
  - 泛经济类和综合类的新闻文本情绪对下一交易日的股票收益率没有显著预测作用;
- **H2b：股吧情绪** 1% 的水平下能够正向预测未来收益率。

H2：文本情绪可以预测股票收益

表 12 文本情绪预测股票收益率

	(1)	(2)	(3)	(4)	(5)
R	经济类	证券类	泛经济类	综合类	股吧文本
L.*NSH*	0.6462*	0.9386**	−0.0980	0.2662	
	(0.3728)	(0.3954)	(0.2988)	(0.4766)	
L.*ESH*					1.1293***
					(0.2322)

表 13 新闻情绪预测股票收益率的中介效应分析

	经济类		证券类	
	(1)	(2)	(3)	(4)
	L.*ESH*	R	L.*ESH*	R
L.*NSH*	0.0907**	0.5629	0.1970***	0.7622*
	(0.0343)	(0.3697)	(0.0350)	(0.3948)
L.*ESH*		0.9184***		0.8959***
		(0.2393)		(0.2434)

- 经济、证券类新闻提供的一系列信息，包含有对未来市场股票回报的预测信息；
- 股吧情绪对股票收益率具有显著预测作用，可作为未来股票价格波动的前瞻信号；
- 中介变量股吧情绪对新闻情绪显著为正：积极的新闻文本情绪会带来投资者情绪升温；
- 股票市场收益率对中介变量股吧情绪的回归系数依然显著为正，中介效应成立。

拓展

- 针对同一政策事件，官方发布的政策原文文本，和自媒体的政策解读文本，二者的情绪的信息含量有什么差异?
- 它们对宏观经济、股市的预测能力有什么不同?

- **自变量**：官方政策文本情绪、自媒体政策解读情绪（用混合式情绪测度方法完成测度）
- **因变量**：宏观经济指标（消费、产出、通胀）、股市收益率 / 波动性

1. 将“传统报刊新闻 vs 股吧发帖”细化到当前政策传播中最核心的两类文本。
2. 本文仅研究了传统报刊和股吧的异质性，没有覆盖当前政策传播中的潜在问题：
   - 大量政策出台后，自媒体的解读会扭曲官方信号，引发市场的过度反应。

构建专属的 N-gram 情绪词典

传统词典仅关注单个词汇，忽略上下文语义，作者针对这个问题：

1. 随机抽取了新闻、股吧各 2 万条语料，由 24 名金融硕士做初步情绪标注，再由专家逐一核对，得到了干净的标注语料库；
2. 从标注语料中，提取 N-gram 短语（而不是单个词汇），比如把“不良率暴涨”作为一个整体的消极短语，解决了单个词汇语义偏差的问题；
3. 针对两类文本的用语差异，分别构建了专属词典：
   - 新闻情绪词典（NSD）：包含 1277 个积极词、2152 个消极词，适配新闻的规范用语；
   - 股吧情绪词典（ESD）：包含 1489 个积极词、2296 个消极词，适配股吧的口语、网络用语；

控制变量、排除遗漏变量

宏观检验的控制变量：

- 预期消费：控制人均可支配收入、住房投资占比、一年期国债利率；
- 预测通胀：控制通胀预期、M2 增长率、银行间 7 天同业拆借利率；
- 预测产出：控制制造业 PMI、PPI、GDP 滞后项；
- 预测利率：控制财政支出增长率、克强指数；
- 同时控制了报纸的个体固定效应、月度的时间固定效应。

股市检验的控制变量：

- 标普 500 收益率（国际市场影响）、原油期货收益率（大宗商品影响）
- GDP 增长率、通胀率、银行间实际利率
- 同时控制了收益率的滞后项、收益率平方的滞后项、动量效应、波动惯性

文本情绪对股票市场预测作用的进一步检验

1. **文本情绪对股票交易量的预测作用**
   - 经济类和证券类文本情绪分散程度的预测回归系数在 5% 水平上显著为负；
   - 股吧文本情绪分散程度的预测系数在 5% 水平上显著为正。
2. **文本情绪对股票收益率波动性的预测作用**
   - 经济类和证券类报纸的新闻文本情绪的绝对值的预测系数均不显著；
   - 股吧文本情绪的绝对值的预测能力系数在 1% 的水平上显著为正。
3. **文本情绪对股票市场收益率的预测作用在不同经济周期的表现**
   - 在经济下行阶段，股吧和经济类报纸文本情绪对股票回报具有更强的预测能力；
   - 然而在经济上行的阶段，均不显著。