投资组合优化中的参数不确定性

汇报人：赵伟皓

武汉大学金融系

2026.04.28

参数不确定性与估计风险

- **马科维茨局限**：在理论完美与实操崩盘间，核心障碍是参数的不确定性（高估计风险）。
- **参数不确定性**：样本均值 $\hat{\mu}$ 和协方差矩阵 $\hat{\Sigma}$ 的估计误差在高维情况下会被剧烈放大。
- **共同主题**：如何从被动接受估计转向**主动控制风险**？

文献 1 (The risk of utility)

通过惩罚效用方差增强稳定性；

从关注“效用期望”转向“效用稳定性”。

文献 2 (Optimal portfolio size)

在有限样本 T 下主动控制参数规模；

在优化权重之前，先确定最优资产数量 N^*。

文献发展脉络

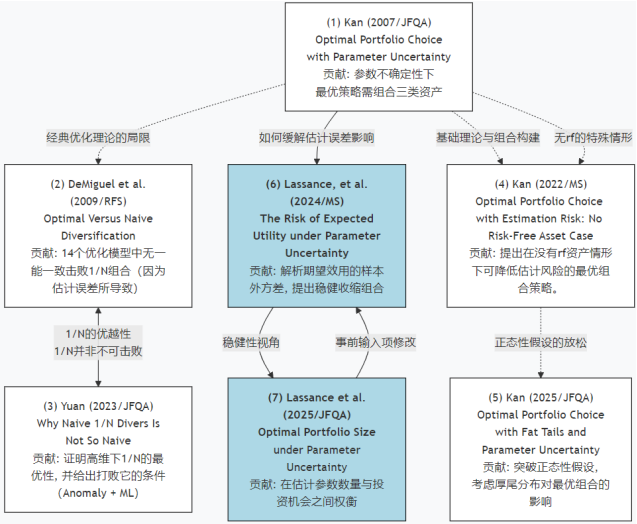
(1) Kan (2007/JFQA)
Optimal Portfolio Choice
with Parameter Uncertainty
贡献: 参数不确定性下
最优策略需组合三类资产
经典优化理论的局限
如何缓解估计误差影响
基础理论与组合构建
无rf的特殊情形
(2) DeMiguel et al.
(2009/RFS)
Optimal Versus Naive
Diversification
贡献: 14个优化模型中无一
能一致击败1/N组合（因为
估计误差所导致）
(6) Lassance, et al.
(2024/MS)
The Risk of Expected
Utility under Parameter
Uncertainty
贡献: 解析期望效用的样本
外方差，提出稳健收缩组合
(4) Kan (2022/MS)
Optimal Portfolio Choice
with Estimation Risk: No
Risk-Free Asset Case
贡献: 提出在没有rf资产情形
下可降低估计风险的最优组
合策略。
1/N的优越性
1/N并非不可击败
稳健性视角
事前输入项修改
正态性假设的放松
(3) Yuan (2023/JFQA)
Why Naive 1/N Divers Is
Not So Naive
贡献: 证明高维下1/N的最
优性，并给出打败它的条件
(Anomaly + ML)
(7) Lassance et al.
(2025/JFQA)
Optimal Portfolio Size
under Parameter
Uncertainty
贡献: 在估计参数数量与投
资机会之间权衡
(5) Kan (2025/JFQA)
Optimal Portfolio Choice
with Fat Tails and
Parameter Uncertainty
贡献: 突破正态性假设，
考虑厚尾分布对最优组合的
影响

效用风险惩罚和资产规模控制

文献 1 ——效用风险惩罚: Lassance et al. (2024) MS

- **逻辑**：优化目标从 $E[U]$ 转向考虑效用分布的权衡 $E[U] - \lambda Var(U)$。
- **策略**：稳健收缩，在均值方差组合与保守的 GMV（全局最小方差）组合之间动态权衡。
  - 单独的均值-方差组合或 GMV 组合都不是最稳健的。
  - 通过“收缩法”将两者结合，可以实现样本外表现的最小波动。

文献 2 ——最优资产规模: Lassance et al. (2025) JFQA

- **逻辑**：在权重优化前，主动剔除“噪声”资产。
- **权衡**：存在一个最优的 N^*（远小于资产总数），使估计风险与收益机会达到数学平衡。
  - 增加资产数量 N：获取更多风险溢价机会（提高理论上限）。
  - 增加资产数量 N：需要估计的参数呈几何倍数增长（增加估计风险）。

The Risk of Expected Utility under Parameter Uncertainty

Nathan Lassance, Alberto Martín-Utrera, Majeed Simaan

Management Science, ***2024***

解读人：赵伟皓

武汉大学金融系

2026.04.28

Research Question

How to characterize risk of expected utility and construct a portfolio under parameter uncertainty?

- How to balance the "oos utility mean-risk" to construct a robust optimal portfolio?[1]
- Expanding the research from the first-order moment (mean) of OOSU to the second-order moment (variance) of it[2].

Not only maximizing the out-of-sample expected utility (mean) , but also controlling its variance.

[1] Mean-Variance & Global Min-Variance is denoted as SMV & SGMV, respectively.
[2] The '**out-of-sample utility**' is denoted as OOSU in the manuscript.

Motivation

1. Existing literature (Kan et al., 2007) mainly focuses on oos **expected utility**(mean)
   - Ignoring that utility itself is a random variable(possiblely with large variance);
   - Utility variance quantify the performance fluctuations caused by parameter uncertainty.
2. Portfolio **construction/evaluation** heavily rely on estimation of $\hat{\mu}$, $\hat{\Sigma}$
   - Portfolios showed poor oos performance due to estimation error (DeMiguel et al., 2009);
   - Researches overlooked the distribution of oos utility when evaluating strategies[3].
     - Mainly focusing on distribution of statistical measures, without risk of performance.
3. Risk of OOSU provides **theoretical explanations** of phenomena
   3.1 Why can't near-arbitrage exist reliably out of the sample?(Kozak et al., 2018)
   3.2 Why is it difficult to reproduce beautiful backtesting results in live trading?

[3] For evaluation, if historical data sequence changes, results may alter(Lo, 2002; Harvey et al., 2014).

Contribution

1. **Literature on OOSU mean under parameter uncertainty**

   Prior: Kan and Zhou (2007) analytically characterized only the expected OOSU.

   Extend: Deriving the variance of OOSU, from average performance to risk of it.

2. **Literature on the out-of-sample distribution**

   Prior: Derived distributions of metrics like the Sharpe ratio for evaluation.[4]

   Extend: Using OOSU volatility to construct strategies(trade-off of OOSU).

3. **Literature on shrinkage estimators**

   Prior: $\hat{\mu}$, $\hat{\Sigma}$ shrinkage for reducing estimation error.[5]

   Extend: Shrinking at **portfolio level** by optimally combining SMV and SGMV.

[4] oos μ,σ^2 distribution (Kan and Smith, 2008); oos SR distribution (Kan et al., 2022a, 2022b)

[5] Shrink or regularize $\hat{\mu}$,$\hat{\Sigma}$ (Jorion, 1986; Ledoit and Wolf, 2004, 2017, 2020).

Linear combination under parameter uncertainty

1. Sample estimation（using $\hat{\mu}, \hat{\Sigma}$): $\hat{w}^\star = \hat{w}_g + \frac{1}{\gamma}\hat{w}_z$
   - Parameters μ and Σ are unknown，requesting estimation as inputs.
   - Estimation error makes the 'optimal' portfolio far from optimal out-of the sample.

2. Combination: Shrinkage between SGMV and SMV

$$\begin{aligned} \hat{w}^\star(\kappa) &= (1-\kappa)\hat{w}_g + \kappa\hat{w}^\star, \quad \kappa \in [0,1] \\ &= \hat{w}_g + \frac{\kappa}{\gamma}\hat{w}_z \end{aligned} \tag{2}$$

3. **The OOSU based on estimation**[6]

$$U(\hat{w}^\star(\kappa)) = \hat{w}^\star(\kappa)^\top \mu - \frac{\gamma}{2}\hat{w}^\star(\kappa)^\top \Sigma \hat{w}^\star(\kappa). \tag{1}$$

[6] Because $\hat{w}^\star(\kappa)$ is estimated from a random sample, the OOSU is on its own a random variable.

OOSU Variance

1. **OOSU Variance of shrinkage portfolio** $\hat{w}^*(\kappa)$

$$\mathbb{V}[U(\hat{w}^*(\kappa))] = \mathbb{V}[U(\hat{w}_g)] + \Delta(\kappa) \tag{2}$$

2. **Eq(4)**[7]: OOSU Variance of SGMV; **Eq(5)**[8]: $\Delta(\kappa)$is a 4th polynomial of κ

$$\mathbb{V}[U(\hat{w}_g)] = \underbrace{\frac{\sigma_g^2\psi^2}{T-N-1}}_{\text{Vol from } \hat{w}_g \text{ and } \mu} + \underbrace{\frac{\gamma^2\sigma_g^4(N-1)(T-2)}{2(T-N-1)^2(T-N-3)}}_{\text{Vol from estimation error of } \hat{\Sigma}} \tag{3}$$

$$\Delta(\kappa) = a_1\kappa^4 + a_2\kappa^3 + a_3\kappa^2 + a_4\kappa \tag{4}$$

[7] Volatility of interaction of $\hat{w}_g$ and μ; Variance penalty volatility caused by $\hat{\Sigma}$ estimation errors

[8] The coefficients a_1, a_2, a_3, a_4 are known functions of $\sigma_g^2, \psi^2, T, N, \gamma$.

Portfolio robustness measure

Mean-Risk OOSU

$$R(\hat{w}) = \mathbb{E}[U(\hat{w})] - \lambda\sqrt{\mathbb{V}[U(\hat{w})]}, \quad \lambda \geq 0$$

- Trade-off between average out-of-sample performance and its stability.
- Asymptotically equivalent to the $\Phi(-\lambda)$, VaR of OOSU.

Robust Shrinkage Portfolio

$$\kappa_R^* = \arg\max_{\kappa \in [0,1]} R(\hat{w}^*(\kappa))$$

- Numerically solved using closed-form $\mathbb{E}[U]$ (IA.2) and $\mathbb{V}[U]$ (Prop. 1).
- Special cases: $\lambda = 0 \Rightarrow \kappa_E^*$; $\lambda \to \infty \Rightarrow \kappa_V^*$.

Trade-off between Max $\mathbb{E}[U]$ and $\mathbb{V}[U]$

Figure 1: Out-of-sample utility efficient frontier

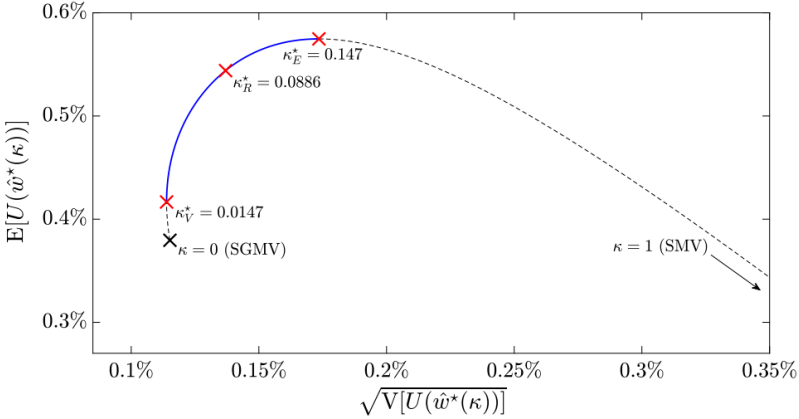

Simulation design (T= 120/180/240)

Gaussian Simulation (Normal distribution) $M = 100000$ **times**

1. Treat $(\hat{\mu}, \hat{\Sigma})$ as DGP: $r_t \sim \mathcal{N}(\hat{\mu}, \hat{\Sigma})$, For each replication:
   - Draw a pseudo-sample of size $T \Rightarrow$ re-estimate $(\hat{\mu}, \hat{\Sigma})$.
   - Construct portfolios $\hat{w}_g, \hat{w}^*, \hat{w}(\kappa)$ and evaluate $U^{(b)}$.
2. Aggregate over $m = 1, \ldots, M$ to obtain OOSU moments and $R(\hat{w}^\star(\kappa))$.

Bootstrap Simulation (Data-driven) 1000 times

1. Resample (with replacement) from the empirical return panel to form $2T$, first-half for in-sample analysis, second-half for oos.
2. Repeat the same pipeline as above (re-estimation $\rightarrow$ portfolio construction $\rightarrow$ OOS evaluation), without making distribution assumptions.

Simulated returns

		OOSU mean			OOSU risk			Mean-risk OOSU		
	T	120	180	240	120	180	240	120	180	240
Panel A: Gaussian data (in %)										
10MOM	$\hat{\kappa}_E^\star$	0.63	0.72	0.77	0.27	0.18	0.15	0.09	0.35	0.47
	$\hat{\kappa}_R^\star$	0.66	0.72	0.76	0.20	0.15	0.13	0.27	0.43	0.50
25SBTM	$\hat{\kappa}_E^\star$	0.45	0.61	0.71	0.37	0.24	0.20	-0.28	0.13	0.31
	$\hat{\kappa}_R^\star$	0.50	0.62	0.70	0.25	0.19	0.17	0.01	0.24	0.36
25OPINV	$\hat{\kappa}_E^\star$	0.67	0.85	0.98	0.38	0.27	0.23	-0.10	0.32	0.52
	$\hat{\kappa}_R^\star$	0.70	0.84	0.95	0.26	0.22	0.21	0.17	0.40	0.52
49IND	$\hat{\kappa}_E^\star$	0.33	0.56	0.70	0.44	0.29	0.23	-0.56	-0.02	0.24
	$\hat{\kappa}_R^\star$	0.40	0.57	0.69	0.26	0.20	0.19	-0.11	0.17	0.31
Panel B: Boostrapped data (in %)										
10MOM	$\hat{\kappa}_E^\star$	0.45	0.54	0.61	0.93	0.63	0.49	-1.41	-0.72	-0.36
	$\hat{\kappa}_R^\star$	0.53	0.58	0.63	0.77	0.54	0.43	-1.01	-0.50	-0.22
25SBTM	$\hat{\kappa}_E^\star$	0.14	0.29	0.43	1.05	0.72	0.57	-1.96	-1.16	-0.71
	$\hat{\kappa}_R^\star$	0.31	0.38	0.48	0.77	0.57	0.46	-1.23	-0.76	-0.45
25OPINV	$\hat{\kappa}_E^\star$	0.37	0.50	0.59	0.82	0.56	0.41	-1.27	-0.61	-0.24
	$\hat{\kappa}_R^\star$	0.47	0.55	0.61	0.63	0.44	0.34	-0.80	-0.33	-0.06
49IND	$\hat{\kappa}_E^\star$	0.07	0.18	0.23	0.69	0.44	0.35	-1.31	-0.69	-0.47
	$\hat{\kappa}_R^\star$	0.21	0.27	0.30	0.50	0.33	0.27	-0.78	-0.39	-0.24

Empirical design

1. **EW**：$(1/N)$；**SGMV**; **SMV**
2. **RTR**：Return-risk timing strategy(Kirby & Ostdiek, 2012)；
3. $\hat{\kappa}_E^*$：Shrinkage portfolio maximizing OOSU mean(Kan et al., 2022b)；
4. $\hat{\kappa}_R^*$：Shrinkage portfolio maximizing mean-risk OOSU.

Datasets(Kenneth French' s website and Novy-Marx and Velikov (2016)

- 10MOM (1927.1 - 2019.12); 25SBTM (1927.1 - 2019.12); 25OPINV (1963.7 - 2019.12); 49IND (1969.7 - 2019.12)
- 16LTANOM (1963.7 - 2013.12); 46ANOM (1973.7 - 2013.12)

Rolling window out-of-sample evaluation：

- Rolling window with a length of $T(= 120$ or 240 months);

Empirical returns

		EW	RTR	SGMV	SMV	$\hat{\kappa}_E^\star$	$\hat{\kappa}_R^\star$
10MOM	Gross OOS CER	0.034	0.051	0.061	0.082	0.115	$\mathbf{0.134}_{\circ\circ\circ}$
	Net OOS CER	0.033	0.049	0.057	0.047	0.082	$\mathbf{0.118}^{\star\star}_{\circ\circ\circ}$
	Gross OOS SR	0.455	0.558	0.641	0.877	0.865	$\mathbf{0.909}_{\circ\circ\circ}$
	Net OOS SR	0.449	0.547	0.611	0.798	0.773	$\mathbf{0.846}^{\star\star}_{\circ\circ\circ}$
	Average $\hat{\kappa}$	/	/	0	1	0.395	0.296
25SBTM	Gross OOS CER	0.045	0.052	0.072	-0.012	**0.123**	$\mathbf{0.123}_{\circ\circ\circ}$
	Net OOS CER	0.044	0.051	0.063	-0.107	0.058	$\mathbf{0.098}^{\star\star}_{\circ\circ\circ}$
	Gross OOS SR	0.522	0.561	0.748	0.813	0.861	$\mathbf{0.991}^{\star\star}_{\circ\circ\circ}$
	Net OOS SR	0.516	0.554	0.679	0.631	0.643	$\mathbf{0.844}^{\star\star\star}_{\circ\circ\circ}$
	Average $\hat{\kappa}$	/	/	0	1	0.214	0.145
25OPINV	Gross OOS CER	0.044	0.055	0.079	-0.269	0.080	$\mathbf{0.102}_{\circ\circ\circ}$
	Net OOS CER	0.043	0.053	0.071	-0.364	0.039	$\mathbf{0.083}^{\star\star\star}_{\circ\circ}$
	Gross OOS SR	0.515	0.586	0.794	0.614	0.699	$\mathbf{0.872}^{\star\star\star}_{\circ\circ\circ}$
	Net OOS SR	0.509	0.575	0.729	0.461	0.538	$\mathbf{0.752}^{\star\star\star}_{\circ}$
	Average $\hat{\kappa}$	/	/	0	1	0.191	0.120
49IND	Gross OOS CER	0.050	0.052	0.053	-1.456	0.039	$\mathbf{0.057}^{\star\star}$
	Net OOS CER	0.049	**0.050**	0.044	-1.565	0.008	$0.046^{\star\star\star}$
	Gross OOS SR	0.552	0.565	0.624	0.264	0.486	$\mathbf{0.645}^{\star\star\star}$
	Net OOS SR	0.544	**0.554**	0.546	0.125	0.279	$0.551^{\star\star\star}$
	Average $\hat{\kappa}$	/	/	0	1	0.043	0.024

Figure 1 复现

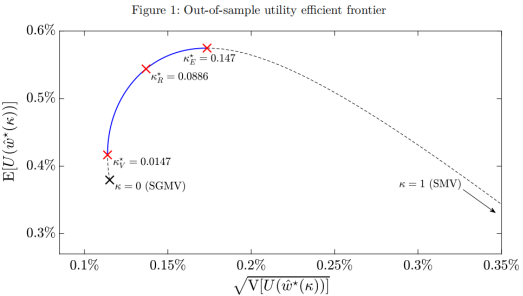
Figure 1: Out-of-sample utility efficient frontier
0.6%
0.5%
0.4%
0.3%
$\mathrm{E}[U(\hat{w}^*(\kappa))]$
$\kappa_E^* = 0.147$
$\kappa_R^* = 0.0886$
$\kappa_V^* = 0.0147$
$\kappa = 0$ (SGMV)
$\kappa = 1$ (SMV)
0.1%
0.15%
0.2%
0.25%
0.3%
0.35%
$\sqrt{\mathrm{V}[U(\hat{w}^*(\kappa))]}$

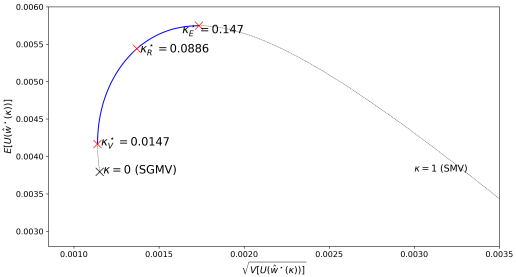
0.0060
0.0055
0.0050
0.0045
0.0040
0.0035
0.0030
$E[U(\hat{w}^*(\kappa))]$
$\kappa_E^* = 0.147$
$\kappa_R^* = 0.0886$
$\kappa_V^* = 0.0147$
$\kappa = 0$ (SGMV)
$\kappa = 1$ (SMV)
0.0010
0.0015
0.0020
0.0025
0.0030
0.0035
$\sqrt{V[U(\hat{w}^*(\kappa))]}$

Table 1 复现

		OOSU mean			OOSU risk			Mean-risk OOSU		
	T	120	180	240	120	180	240	120	180	240
原文 Panel A: Gaussian data (in %)										
$10MOM$	$\hat{\kappa}_E^*$	0.63	0.72	0.77	0.27	0.18	0.15	0.09	0.35	0.47
	$\hat{\kappa}_R^*$	0.66	0.72	0.76	0.20	0.15	0.13	0.27	0.43	0.50
原文 Panel B: Bootstrapped data (in %)										
$10MOM$	$\hat{\kappa}_E^*$	0.45	0.54	0.61	0.93	0.63	0.49	-1.41	-0.72	-0.36
	$\hat{\kappa}_R^*$	0.53	0.58	0.63	0.77	0.54	0.43	-1.01	-0.50	-0.22
复现 Panel A: Gaussian (in %)										
$10MOM$	$\hat{\kappa}_E^*$	0.634	0.718	0.770	0.269	0.187	0.148	0.097	0.345	0.475
	$\hat{\kappa}_R^*$	0.664	0.719	0.760	0.194	0.148	0.128	0.275	0.423	0.504
复现 Panel B: Bootstrap (in %)										
$10MOM$	$\hat{\kappa}_E^*$	0.522	0.646	0.720	0.978	0.710	0.582	-1.434	-0.775	-0.445
	$\hat{\kappa}_R^*$	0.580	0.666	0.724	0.815	0.620	0.524	-1.05	-0.575	-0.325

Table 2 复现

Dataset	原文	EW	RTR	SGMV	SMV	$\hat{\kappa}_E$	$\hat{\kappa}_R$
10MOM	Gross CER	0.034	0.051	0.061	0.082	0.115	$\mathbf{0.134}_{\circ\circ\circ}$
	Net CER	0.033	0.049	0.057	0.047	0.082	$\mathbf{0.118}^{**}_{\circ\circ\circ}$
	Gross SR	0.455	0.558	0.641	0.877	0.865	$\mathbf{0.909}_{\circ\circ\circ}$
	Net SR	0.449	0.547	0.611	0.798	0.773	$\mathbf{0.846}^{**}_{\circ\circ\circ}$
	Average $\hat{\kappa}$	/	/	0	1	0.395	0.296

Dataset	复现	EW	RTR	SGMV	SMV	$\hat{\kappa}_E$	$\hat{\kappa}_R$
10MOM	Gross CER	0.0339	0.0509	0.0613	0.0822	0.1166	$\mathbf{0.1324}_{\circ\circ\circ}$
	Net CER	0.0329	0.0493	0.0570	0.0469	0.0837	$\mathbf{0.1158}^{**}_{\circ\circ\circ}$
	Gross SR	0.4549	0.5575	0.6405	0.8766	0.8692	$\mathbf{0.9059}_{\circ\circ\circ}$
	Net SR	0.4493	0.5474	0.6132	0.7981	0.7784	$\mathbf{0.8391}^{**}_{\circ\circ\circ}$
	Average $\hat{\kappa}$	–	–	0.0000	1.0000	0.3947	0.2962

Table 2 p-values

表: One-sided p-values: $\hat{\kappa}_R^\star$ relative to EW

Dataset	Metric	p-value
10MOM	Gross CER	0.0000
	Net CER	0.0000
	Gross SR	0.0000
	Net SR	0.0000

表: One-sided p-values: $\hat{\kappa}_R^\star$ relative to $\hat{\kappa}_E^\star$

Dataset	Metric	p-value
10MOM	Gross CER	0.1790
	Net CER	0.0230
	Gross SR	0.1850
	Net SR	0.0520

考虑效用权衡的 DFL

研究问题

- 在 DFL 中，若将目标从**最大化期望效用**扩展为**最大化效用均值并惩罚效用风险**，能否在不显著牺牲平均表现的前提下，获得更稳定、更稳健的样本外效用？

研究动机

- 现有 DFL 大多只优化期望效用，忽视效用波动与尾部风险；
- 金融决策更关注“长期可持续的稳定表现”，而非仅一次性高均值。

研究贡献

- 提出风险感知的 DFL 目标：$\max \mathbb{E}[U] - \lambda \mathbb{V}(U)$
- 将“均值-风险”效用思想系统并入预测-决策一体化框架。
- 提供可解释的风险偏好参数 λ，实现**效用期望-稳定性**可控权衡。

研究假设

1. 风险惩罚项可显著降低样本外效用波动与尾部损失。
2. 在合理 λ 区间内，平均效用仅小幅下降或保持不变。

时间序列波动 vs. 抽样分布波动

在理解参数不确定性（Parameter Uncertainty）时，我们必须严格区分两种“波动”：

1. 资产收益在“时间序列”上的波动（市场风险）
   - 这是指在一个固定的投资组合下，由于市场行情的涨跌，导致你的组合收益在这个月赚 5%，下个月亏 3%。
   - 在均值-方差框架里，这种波动已经被协方差矩阵 Σ 惩罚过了。
2. 样本外效用在“不同抽样样本”间的波动（估计风险）
   - **OOSU 的方差是指：假设你有两个基金经理，使用完全相同的模型逻辑：**
   - 基金经理 A 使用 2010-2015 年的历史数据算出一套权重，基金经理 B 使用 2011-2016 年的历史数据算出一套权重。
   - 当他们拿着各自算出的权重去面对未来的真实市场时，A 的真实效用是 1.2，而 B 的真实效用是 -0.8。
   - 这种因为“喂给模型的数据样本不同”导致“最终表现天差地别”的现象，才是 OOSU 的方差。

Utility Function of SMV & SGMV

N risky assets, return of μ, cov matrix of Σ. Satisfying $w^\top e = 1$.[9]

1. Sample Mean-Variance (SMV)[10]

$$\max_w \; U(w) = w^\top \mu - \frac{\gamma}{2} w^\top \Sigma w$$

$$w_z = \Sigma^{-1}(\mu - \mu w_g^\top e), \quad \psi^2 = w_z^\top \Sigma w_z$$

$$w^\star = w_g + \frac{1}{\gamma} w_z$$

2. Sample Global Min-Variance (SGMV)

$$\min_{w_g} \; U(w) = \frac{1}{2} w_g^\top \Sigma w_g$$

$$\mu_g = w_g^\top \mu, \qquad \sigma_g^2 = w_g^\top \Sigma w_g$$

$$w_g = \Sigma^{-1} e (e^\top \Sigma^{-1} e)^{-1}$$

Mean-Variance utility, given $w^\star$, $U(w)$, $U(w_g)$, ψ^2, doing linear algebra.

$$U(w^\star) = U(w_g) + \frac{\psi^2}{2\gamma} \tag{5}$$

[9] e is a vector where all elements are 1.

[10] $w^\star$ is the optimal weight for two-fund rule under SMV; w_z is the Zero-cost portfolio, $w_z^\top e = 0$

两基金分离推导

Step 1：求解 GMV 组合 w_g

$$\mathcal{L}(w_g, \lambda) = \frac{1}{2} w_g^\top \Sigma w_g - \lambda(w_g^\top e - 1)$$

$$\frac{\partial \mathcal{L}}{\partial w_g} = \Sigma w_g - \lambda e = 0 \implies w_g = \lambda \Sigma^{-1} e$$

$$\text{代入约束：} \lambda e^\top \Sigma^{-1} e = 1 \implies \lambda = \frac{1}{e^\top \Sigma^{-1} e} \Rightarrow w_g = \Sigma^{-1} e \big(e^\top \Sigma^{-1} e\big)^{-1}$$

Step 2：求解 MV 最优组合 $w^\star$ 并分离出 w_z

$$\mathcal{L}(w, \delta) = w^\top \mu - \frac{\gamma}{2} w^\top \Sigma w - \delta(w^\top e - 1)$$

$$\frac{\partial \mathcal{L}}{\partial w} = \mu - \gamma \Sigma w - \delta e = 0 \implies w = \frac{1}{\gamma} \Sigma^{-1} (\mu - \delta e)$$

$$\text{利用} w^\top e = 1 \text{ 解得} \delta = \mu_g - \gamma \sigma_g^2 \quad \big(\mu_g \equiv w_g^\top \mu,\ \sigma_g^2 \equiv w_g^\top \Sigma w_g\big)$$

$$\Rightarrow w^\star = \frac{1}{\gamma} \Sigma^{-1} (\mu - \mu_g e) + \Sigma^{-1} e \sigma_g^2 = w_g + \frac{1}{\gamma} \underbrace{\Sigma^{-1} (\mu - \mu_g e)}_{=: w_z}$$

最优均值-方差效用的分解推导

已知：

- 最优投资组合：$w^\star = w_g + \frac{1}{\gamma} w_z$
- 效用函数：$U(w) = w^\top \mu - \frac{\gamma}{2} w^\top \Sigma w$
- GMV 组合效用：$U(w_g) = \mu_g - \frac{\gamma}{2}\sigma_g^2$
- $\psi^2 \equiv w_z^\top \Sigma w_z$，且可验证 $w_z^\top \mu = \psi^2$，$w_g^\top \Sigma w_z = 0$

$$(w^\star)^\top \mu = \left(w_g + \frac{1}{\gamma} w_z\right)^\top \mu = w_g^\top \mu + \frac{1}{\gamma} w_z^\top \mu = \mu_g + \frac{1}{\gamma}\psi^2 (\text{代入 } w_z^\top \mu = \psi^2)$$

$$(w^\star)^\top \Sigma w^\star = \left(w_g + \frac{1}{\gamma} w_z\right)^\top \Sigma \left(w_g + \frac{1}{\gamma} w_z\right) = w_g^\top \Sigma w_g + \frac{2}{\gamma} \underbrace{w_g^\top \Sigma w_z}_{=0} + \frac{1}{\gamma^2} w_z^\top \Sigma w_z = \sigma_g^2 + \frac{1}{\gamma^2}\psi^2$$

$$U(w^\star) = \underbrace{\left(\mu_g + \frac{1}{\gamma}\psi^2\right)}_{\text{预期收益}} - \frac{\gamma}{2} \underbrace{\left(\sigma_g^2 + \frac{1}{\gamma^2}\psi^2\right)}_{\text{方差}} = \left(\mu_g - \frac{\gamma}{2}\sigma_g^2\right) + \frac{1}{\gamma}\psi^2 - \frac{1}{2\gamma}\psi^2 = U(w_g) + \frac{\psi^2}{2\gamma}$$

推导 2

$w_z^\top \mu = \psi^2$：

$$w_z = \Sigma^{-1}(\mu - \mu_g e) \Rightarrow w_z^\top \mu = (\mu - \mu_g e)^\top \Sigma^{-1} \mu = \mu^\top \Sigma^{-1} \mu - \mu_g e^\top \Sigma^{-1} \mu$$

$$\psi^2 = w_z^\top \Sigma w_z = (\mu - \mu_g e)^\top \Sigma^{-1} (\mu - \mu_g e) = \mu^\top \Sigma^{-1} \mu - \mu_g e^\top \Sigma^{-1} \mu$$

$w_g^\top \Sigma w_z = 0$：

$$w_g^\top \Sigma w_z = w_g^\top \Sigma \cdot \Sigma^{-1}(\mu - \mu_g e) = w_g^\top (\mu - \mu_g e) = w_g^\top \mu - \mu_g = \mu_g - \mu_g = 0$$

最优（均值方差）投资组合的全部效用，可分解为**被动效用** $U(w_g)$ 与**主动收益增量** $\frac{\psi^2}{2\gamma}$ 之和。交叉项因 w_g 与 w_z 正交而消失。

OOSU 方差

$$\Delta(\kappa) = a_1\kappa^4 + a_2\kappa^3 + a_3\kappa^2 + a_4\kappa.$$

$$a_1 = \frac{1}{2\gamma^2}\,\frac{T^2(T-2)\,C(T,N,\psi^2)}{(T-N)^2(T-N-1)^2(T-N-2)(T-N-3)^2(T-N-5)(T-N-7)}$$

$$a_2 = -\frac{2}{\gamma^2}\,\frac{4\psi^2T^3(T-2)+T^2(T-2)(T+N-3)}{(T-N)(T-N-1)^2(T-N-3)(T-N-5)}$$

$$a_3 = \frac{2T(N+1)+T^2\big(T-N-3+2(T-N)\psi^2\big)}{\gamma^2\,(T-N)(T-N-1)^2(T-N-3)} + \frac{4\,\sigma_g^2\,T(T-2)(T+N-3)(T\psi^2+N-1)}{\gamma^2\,(T-N)(T-N-1)^2(T-N-3)(T-N-5)}$$

$$a_4 = -\frac{2}{\gamma}\,\sigma_g^2\,\psi^2\,\frac{T(T-2)}{(T-N-1)^2(T-N-3)}$$

- $C(T,N,\psi^2)$ is a polynomial in T,N,ψ^2 given explicitly in the proof.
- Sign of $a_4 < 0$ drives the initial decline of OOSU variance for small κ.

OOSU 方差

收缩投资组合 $\hat{w}^*(\kappa)$ 本质上是 SGMV（$\hat{w}_g$）与零成本多空组合（$\hat{w}_z$）的线性组合：

$$\hat{w}^*(\kappa) = \hat{w}_g + \kappa \hat{w}_z$$

当我们把这个权重代入真实的效用函数 $U(w) = w^\top \mu - \frac{\gamma}{2} w^\top \Sigma w$ 时，效用函数就变成了一个关于 κ 的一元二次方程：

$$U(\hat{w}^*(\kappa)) = \underbrace{U(\hat{w}_g)}_{\text{常数项}} + \kappa \cdot \underbrace{(\hat{w}_z^\top \mu - \gamma \hat{w}_g^\top \Sigma \hat{w}_z)}_{\text{一次项系数}} - \kappa^2 \cdot \underbrace{(\frac{\gamma}{2} \hat{w}_z^\top \Sigma \hat{w}_z)}_{\text{二次项系数}}$$

简写为：$U(\kappa) = U_0 + \kappa U_1 - \kappa^2 U_2$ 这里的 U_0, U_1, U_2 都是带有参数估计误差的随机变量。既然效用本身是 κ 的二次函数，那么求效用的方差 $\mathbb{V}[U(\kappa)]$ 时，自然会产生一个最高次为 κ^4 的多项式。这四个次方，本质上是对 U_0, U_1, U_2 这三个随机变量的方差和协方差的展开。

OOSU 方差

1. κ^4 **项：主动风险惩罚：**主要来自 $\mathbb{V}[\kappa^2 U_2]$，即 $\kappa^4 \mathbb{V}[\frac{\gamma}{2}\hat{w}_z^\top \Sigma \hat{w}_z]$。
这是风险惩罚项波动的方差。当 κ 变大时（即给高预期收益的资产分配更高权重），组合的真实风险（方差）是呈平方级数 κ^2 爆炸的。因此，这种平方级数的风险爆炸本身也充满了极大的不确定性。κ^4 代表：过度依赖估计出的均值去放大敞口，会导致样本外风险惩罚的剧烈波动。

2. κ^2 **项：预期收益与基础风险的关系：**主要来自一次项的方差 $\mathbb{V}[\kappa U_1]$，以及常数项与二次项的协方差 $Cov(U_0, -\kappa^2 U_2)$。
这一项主导了适度配置主动权重时的表现风险。它反映了由于估计（$\hat{\mu}$ 的误差），导致主动调仓（$\kappa\hat{w}_z$）时，不仅预期收益会发生大幅偏离，还可能意外地破坏了原本 SGMV 组合（$\hat{w}_g$）的低风险特性。

3. κ^3 **和** κ **项：误差的协方差项：**κ^3 来自 $Cov(\kappa U_1, -\kappa^2 U_2)$；$\kappa$ 来自 $Cov(U_0, \kappa U_1)$。
这代表了不同类型估计误差之间的交互作用。例如，κ^3 项反映了预期收益的估计误差与协方差上的估计误差不是独立的。

Empirical returns

		Mean OOS CER		Std dev OOS CER	
		$T = 120$	$T = 240$	$T = 120$	$T = 240$
Panel A: Without transaction costs (in %)					
10MOM	$\hat{\kappa}_E^\star$	1.027	1.205	2.444	2.631
	$\boxed{\hat{\kappa}_R^\star}$	1.138	1.312	1.576	2.031
25SBTM	$\hat{\kappa}_E^\star$	1.074	1.230	1.555	1.739
	$\boxed{\hat{\kappa}_R^\star}$	1.028	1.255	1.071	1.051
25OPINV	$\hat{\kappa}_E^\star$	0.613	0.945	1.315	1.198
	$\boxed{\hat{\kappa}_R^\star}$	0.831	1.118	0.997	0.888
49IND	$\hat{\kappa}_E^\star$	0.361	0.252	1.178	0.927
	$\boxed{\hat{\kappa}_R^\star}$	0.522	0.425	0.841	0.786
Panel B: Net of transaction costs (in %)					
10MOM	$\hat{\kappa}_E^\star$	0.743	1.037	2.422	2.628
	$\boxed{\hat{\kappa}_R^\star}$	1.002	1.201	1.565	2.040
25SBTM	$\hat{\kappa}_E^\star$	0.515	0.861	1.362	1.769
	$\boxed{\hat{\kappa}_R^\star}$	0.819	0.977	1.012	1.002
25OPINV	$\hat{\kappa}_E^\star$	0.260	0.737	1.339	1.188
	$\boxed{\hat{\kappa}_R^\star}$	0.666	0.986	1.001	0.878
49IND	$\hat{\kappa}_E^\star$	0.098	0.113	1.170	0.943
	$\boxed{\hat{\kappa}_R^\star}$	0.423	0.344	0.834	0.807

OOSU 方差的单调性

1. 样本量（T）和收敛性的影响

- $\mathbb{V}[U(\hat{w}^*(\kappa))]$ **随样本量 T 增大而下降**并在 $T \to \infty$ 时收敛至 0。
- 样本量 T 越大 $\Rightarrow$ 估计误差越小 $\Rightarrow$ 样本外效用的确定性越高。

2. OOSU 方差的上升驱动因素：

N (资产数): 固定样本量 T 时，待估计参数更多；维度灾难会加剧投资组合业绩波动。

σ_g^2 (GMV 方差): 基准市场风险越高，各类估计偏差对投资者福利的冲击就越强。

ψ^2 (w_z 方差): 样本内的近似套利机会越强，越容易催生极端主动持仓，而这类持仓在样本外极度脆弱；且该负面影响会随 κ 增大而加剧。

$\kappa \geq \kappa_E^*$ 区间内的 κ: 一旦超出最大化平均样本外效用的临界点，继续提高均值-方差组合的权重占比，会同时推高风险、降低期望效用，形成双重负面惩罚。

结论：在任意合理的有限样本环境下，**SMV 的 OOSU 风险远高于 SGMV**。通过收缩估计降低均值-方差组合的暴露程度，是控制投资组合业绩不确定性的关键手段。

近套利机会与 ψ^2 的联系 I

核心问题：为什么低波动主成分上的高夏普策略在样本外极其脆弱？

协方差矩阵 Σ 的特征值分解

$$\Sigma = \mathbf{V}\mathbf{D}\mathbf{V}^\top, \quad \mathbf{D} = \mathrm{diag}(d_1, \ldots, d_N),\ d_1 \geq \cdots \geq d_N > 0$$

- 每个特征向量 v_i 定义一个**主成分组合**，收益方差为 d_i。
- 高方差主成分（d_1 大）对应整体市场风险；**低方差主成分**（d_i 小）几乎被对冲掉，波动极低。

近套利机会与 ψ^2 的联系 II

命题 6（等价性）假设第一特征向量近似于等权重组合，则零成本组合的方差可写为

$$\boxed{\psi^2 = \sum_{i>1}^{N} SR_{PC_i}^2}$$

其中 $SR_{PC_i} = v_i^\top \mu / \sqrt{d_i}$ 是第 i 个主成分的夏普比率。

含义

- ψ^2 度量了资产间收益预测差异的强度，即**多空套利信号的总强度**。
- 当某个**低方差主成分**具有极高夏普比率时，就出现了**近似套利机会**：几乎零风险、零成本、正预期收益。

近套利机会与 ψ^2 的联系 III

- 但低方差意味着巨大的杠杆放大（Σ^{-1} 中 $1/d_i$ 极大），任何均值估计的微小误差都会引发效用的剧烈波动。
- 因此 ψ^2 既是套利机会的度量，也是 **OOSU 风险的度量**：ψ^2 越大，样本外效用方差越大（命题 2）。

直觉：一把极窄的尺子（低波动主成分）能获得极高精度（高夏普），但手稍抖（估计误差）就错得离谱——样本内的高夏普往往源自噪声，样本外必然剧烈波动。