
信贷违约预测
Adams et al. (2009, AER)
人口特征、收入、资产状况等
Einav et al. (2012, Econometrica)
征信记录、历史逾期、信用评分、账户及还款行为
电商消费、数字足迹、交易数据、教育/就业、手机游戏、表情等另类数据;
胡俊等（2025，管科）
Berg et al.（2020，RFS）
Di Maggio and Ratnadiwakara（2026，MS）
Gong et al.（2024，MS）
个人信贷
Jiménez & Saurina (2004, JBF)
企业基本财务特征、抵押与担保信息等
Norden & Weber (2010, RFS)
账户流水、现金流、交易账户信息等
发票、税务、工商文本、银企关系等
冯丽璇等（2026, WP）
Minnis & Sutherland (2017，JAR)
李铁等，（2026，管科）
史金艳等（2025，中工）
企业信贷
传统信息：静态特征
进一步拓展：动态/相关行为信息
前沿：另类数据

数字足迹与违约预测：基于消费信贷的证据

胡俊，李强，曾勇，田轩，刘嵩
（管理科学学报，2025）

石宛青

Department of Finance
Wuhan University

2026 年 9 月 20 日

Question

- 数字足迹（电商信用评分和网购行为）能否改善消费信贷违约预测？
  - 核心结论：相比自我报告 + 央行征信，AUC 约提升 50%
  - 微观经济机制：足迹相关指标通过反映消费偏好或行为特征以预测
  - 提高信贷可得性机理：信用白户建立数字信用，误估的“劣质”客群重新准确评估

Why interesting?

- 依托金融科技提高普惠性是全面促进消费的重要手段. 我国消费信贷增长迅速.
- 传统信贷模式面临挑战：授信成本高、风控难度大 ⇒ 覆盖范围有限
  - **消费金融场景：**贷款小额、分散、无抵押
  - **传统征信不足：**我国个人征信体系不健全: 自报信息-操纵；白户-传统模型难识别
- 以大数据和机器学习为代表的数字技术与消费金融业务深度融合
  - 智能手机、网络购物和社交媒体催生“数据资产化”的大数据公司
  - 金融机构能够通过合作或购买获得借款人画像的多维异构数据进行信用风险评估
- **数字足迹（电商信用评分和网购行为）的潜在优势:**
  - 线上消费、支付、地址等难以完全伪造
  - 高频、连续、覆盖广，能够反映长期行为习惯
  - ⇒ 可与机器学习/大数据风控结合，补充传统征信信息

Contribution

- 信贷违约预测相关研究
  - 从“综合评分”深入到底层数字足迹
    - prior：主要比较金融科技信用评分与传统征信（Jiang et al.，2021），但评分“黑箱”
    - 首次利用底层网购数据，发现其增量预测能力，且与电商信用评分存在显著互补性。
  - 探讨并定量考察了网购足迹预测违约的微观机制
    - prior：定性讨论了网购行为能够识别个人违约的可能原因（王正位等，2020）
    - 提供了实证证据, 发现足迹通过反映消费偏好或行为特征以预测违约的经济机制

Design--数据与样本

- 国内某持牌金融科技借贷机构
- 2016. 4—2017. 4 申请借款且有电商评分和网购订单信息的 48275 个借款人
- Y: 是否违约 (Default): 超过约定还款日后的规定天数仍未还款, 定义为违约 (Default=1)
- X: 四类信息
  1. 借款申请时自我报告: 性别、年龄、婚姻等人口特征, 及身份证、手机号认证情况
  2. 央行征信的银行卡信息: 卡类型、开户行名称等
  3. 从国内某大型电商平台获取的个人电商信用评分
  4. 从另一家大型电商平台获取的历史逐笔网购订单数据

Design--数据与样本

类型	名称及符号	定义及说明
自我报告信息	手机认证(*Phone_Y*)	通过手机认证为1,否则为0
	身份证认证(*Idcard_Y*)	通过身份证认证为1,否则为0
	会员等级(*Account_G*)	黄金和钻石会员为1,其他为0
	绑定 QQ(*QQ_bound*)	绑定 QQ 为1,否则为0
	绑定微信(*Wechat_bound*)	绑定微信为1,否则为0
	年龄分类(*Age_i*)	$i=1,2,3$,分别代表年龄小于30岁,30~40岁及40~60岁取值为1,其他为0,基准为没有报告年龄
	性别分类(*Sex_i*)	$i=1,2$,分别表示男性、女性为1,其他为0,基准为没有报告性别
	收入分类(*Income_i*)	$i=1,2$,分别表示收入6 000元以上和以下为1,其他为0,基准为没有报告收入
	婚姻分类(*Merri_i*)	$i=1,2$,分别表示未婚和已婚为1,其他为0,基准是没有报告婚姻状况
	学历分类(*Edu_i*)	$i=1,2$,分别表示本科及以上,本科以下为1,其他为0,基准是没有报告学历
	信息缺失比例(*Null_num*)	在填写信息项中缺失项数除以总项数
央行征信信息	银行卡开户行个数(*Bankname_num*)	所有银行卡的开户行个数
	绑定手机号个数(*Bankphone_num*)	所有银行卡绑定不同手机号的个数
	信用卡张数(*Creditcard_num*)	信用卡的张数
	储蓄卡张数(*Depositcard_num*)	储蓄卡的张数
	信用卡开户行个数(*Creditbank_num*)	信用卡开户行的个数
	储蓄卡开户行个数(*Depositbank_num*)	储蓄卡开户行的个数
	国有开户行个数(*Statbankname_num*)	所有银行卡的开户行中国有银行的个数

类型	名称及符号	定义及说明
电商信用评分和网购行为足迹	电商信用评分(*E_creditscore*)	电商平台对该借款人的信用评分
	网购开始年份(*First_order_i*)	$i=1,2,3$,分别表示是否在2013年及以前,2014年—2015年,2016年开始网购为1,其他为0,基准是2017年开始网购
	货到付款比例(*Delivery_pay_ratio*)	借款前3年的订单中,货到付款订单的比例
	取消订单比例(*Order_cancel_ratio*)	借款前3年的订单中,取消订单的比例
	凌晨下单比例(*Order_night_ratio*)	借款前3年的订单中,凌晨下单的比例
	工作时间下单比例(*Order_workhour_ratio*)	借款前3年的订单中,星期一至星期五的早上九点至下午五点下单的比例
	工作日下单比例(*Order_workday_ratio*)	借款前3年的订单中,星期一至星期五下单的比例
	借款前3年订单金额统计量(*Order_**_year3*)	*为通配符,包括借款前3年的订单笔数,交易金额的最大值、最小值、标准差、均值
	借款前半年订单金额统计量(*Order_**_hyear*)	*为通配符,包括借款前半年的订单笔数,交易金额的最大值、最小值、标准差、均值
	收货地址个数(*Recive_addr_num*)	历史收货地址的个数
	收货城市个数(*Recieve_city_num*)	收货地址中不同城市的个数
	收货地址中乡镇比例(*Town*)	收货地址为镇或乡的个数占收货地址总个数的比例
	收货电话个数(*Recieve_phone_num*)	收货地址信息中收货人电话的个数
	收货人个数(*Receiver_num*)	收货地址信息中收货人的个数

Design--模型

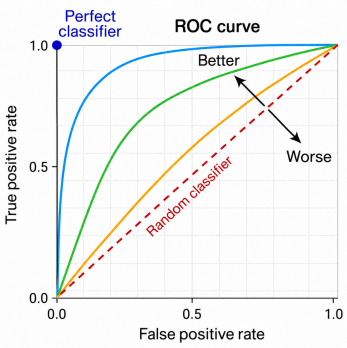
- Logit 回归模型：

$$\text{Default}_i = \alpha_0 + \beta_1 \text{Selfreport}_i + \beta_2 \text{Centralcredit}_i + \beta_3 \text{Thirdscore}_i + \beta_4 \text{Behavior}_i + \eta_t + \varepsilon_i.$$

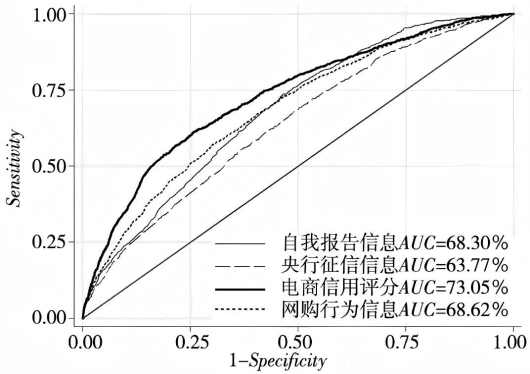
- 评价指标：AUC—ROC 曲线下面积，取值 0.5–1

参考范围（Iyer et al., 2016）：

- 信息含量较低时，模型 AUC 目标是 60%
- AUC 达到 70% 以上时，表明信息含量较丰富、预测能力较好
- AUC 每提高 1%，对信用风险评估均具有重要经济价值



result-不同类型信息单独用于违约预测的 ROC 曲线



- 将四类信息同时加入回归的结果显示:AUC 值可以高达 80.64%

result-异质性检验-经济机制

- 通过异质性检验, 探索性地为网购行为足迹用于违约预测的经济机制提供证据.
  - 网购金额: 反映了个人或家庭的消费和经济状况; 女性承担更多的家庭消费角色

变量名称	(1)	(2)	(3)
	报告性别的子样本	男性子样本	女性子样本
Order_mean_hyear	-0.066 6*	-0.045 9	-0.294 6**
	(-1.915 2)	(-1.278 2)	(-2.084 7)

  - 凌晨下单比例：0 点-6 点的线上活动越频繁, 其自控力越差, 工作日更甚

变量名称	(1)	(2)	(3)
		不考虑法定节假日划分休息日和工作日	考虑法定节假日划分休息日和工作日
Order_night_ratio	0.631 7***		
	(5.754 2)		
Order_night_ratio_week		0.180 8	0.116 4
		(1.354 7)	(0.848 6)
Order_night_ratio_work		0.604 1***	0.639 1***
		(5.509 7)	(5.840 7)

• result-异质性检验-经济机制

- 通过异质性检验, 探索性地为网购行为足迹用于违约预测的经济机制提供证据.
  - 取消订单比例：视为履约能力差的表现; 履约能力还与所在区域整体信用环境有关

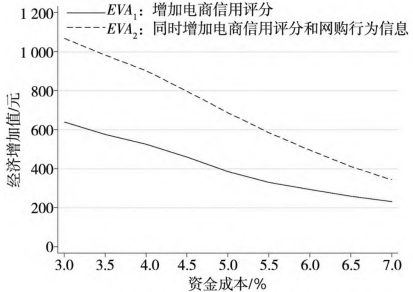
变量名称	(1)	(2)	(3)	(4)	(5)
	全样本	城市信用综合指数		数字信用发展程度	
		低	高	低	高
Order_cancel_ratio	1. 118 6***	1. 308 4***	0. 912 4***	1. 285 1***	0. 932 9***
	(11. 158 2)	(9. 170 8)	(6. 384 0)	(9. 058 0)	(6. 508 3)

  - 货到付款比例：事先付款的履约意愿，尤其是买小金额、物流快、支付工具普及高时

变量名称	(1)	(2)	(3)	(4)	(5)	(6)
	全样本	物流时效性		支付工具普及率		网购订单金额大小
		低	高	低	高	
Delivery_pay_ratio	0. 599 2***	0. 232 3	0. 884 4***	0. 111 9	0. 726 5***	
	(4. 861 8)	(1. 214 4)	(5. 488 0)	(0. 414 4)	(5. 260 5)	
Delivery_pay_ratio_big						0. 230 9
						(1. 591 9)
Delivery_pay_ratio_small						0. 414 3***
						(2. 878 8)

result-经济价值

- 数值模拟优化：
  1. 模型为每位申请者估计违约概率
  2. 调整放贷门槛，在“贷款通过率更高”和“贷后违约率更低”之间权衡，使借款的期望净现值 (NPV) 最大
  3. 加入数字足迹后最大期望净现值的增量，即为数字足迹的经济增加值（EVA）



- 若同时使用两类数字足迹, 每笔借款申请的经济增加值为 343-1069 元

result-数字足迹提高信贷可得性的机理分析

- 信用白户的信贷可得性分析
  - 2017 年 11 月, 央行征信中心收录 9.5 亿自然人信息, 但其中仅有 4.8 亿人有借贷记录--促进消费升级和推动普惠金融发展.

变量类型	(1)	(2)	(3)	(4)
	信用卡		国有银行信用卡	
	无	有	无	有
自我报告信息 + 央行征信信息	0.674 2	0.728 4	0.688 1	0.763 8
自我报告信息 + 央行征信信息 + 电商信用评分 + 网购行为足迹	0.788 1	0.820 2	0.795 2	0.846 7

  - 无信用卡的提高幅度分高达 50% 、39%，大幅高于有信用卡幅度（19% 、10%）

result-数字足迹提高信贷可得性的机理分析

- “劣质”客群的信贷可得性分析
  - 因央行征信记录不良或受外部冲击而被传统征信评估认定为“劣质”的老客群.
  - 分组：根据预测概率分组，考察组合真实违约概率。设风险最高的借款人被拒贷

未使用数字足迹预测的违约概率	使用数字足迹预测的违约概率			
	低	中	高	全样本
低	0.001 9 [6 882]	0.009 1 [1 754]	0.027 1 [332]	0.004 2 [8 968]
中	0.001 6 [1 894]	0.009 1 [4 524]	0.041 6 [2 549]	0.016 7 [8 967]
高	0.005 2 [192]	0.010 0 [2 689]	0.050 6 [6 086]	0.037 5 [8 967]
全样本	0.001 9 [8 968]	0.009 4 [8 967]	0.047 2 [8 967]	0.019 4 [26 902]

  - 合计占比为 (192+2689)/ 8967=32.13% 的借款人因重新被评估为非高风险而可以获得借款, 这部分人的真实违约概率比总体平均还低。

Idea

- 其他另类数据：
  - 企业用电数据，物流/运单（真实生产活动）
  - 政府采购/中标（未来订单、收入确定性）
- 连续实时数据能否更早发现信用恶化？
  - 足迹数据有实时性：更适合用于贷后管理、动态额度调整、风险预警和催收
- 数字信息能否替代抵押品？
  - 没有抵押品的企业中，另类数据能不能准确找到“低违约风险企业”？
  - 金融科技能否使缺乏抵押品的优质小微企业获得信用贷款，而不提高违约风险？

变量名称	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)
自我报告信息	是	否	否	否	否	是	是	是	是
央行征信信息	否	是	否	否	否	是	是	是	是
E_creditscore			−0.009 6***		−0.010 4***		−0.010 1***		−0.010 4***
			(−25.814 8)		(−25.855 5)		(−24.516 9)		(−24.089 2)
网购行为足迹*:									
Delivery_pay_ratio				0.954 6***	0.777 9***			0.820 9***	0.779 2***
				(7.894 1)	(6.495 2)			(6.547 7)	(6.271 4)
Order_cancel_ratio				1.211 7***	0.674 2***			1.066 8***	0.639 3***
				(11.777 5)	(6.425 3)			(10.098 5)	(5.906 0)
Order_night_ratio				0.763 2***	0.554 1***			0.700 6***	0.513 6***
				(5.883 7)	(4.478 0)			(5.320 2)	(3.983 7)
Order_workhour_ratio				−0.023 8	−0.036 1			−0.042 2	−0.042 6
				(−0.174 7)	(−0.293 5)			(−0.310 4)	(−0.335 6)
Order_workday_ratio				−0.195 7	−0.126 5			−0.184 1	−0.132 0
				(−1.531 7)	(−1.083 4)			(−1.437 5)	(−1.090 4)
Order_num_year3				0.000 0	0.000 5***			0.000 3*	0.000 4***
				(0.026 7)	(3.007 4)			(1.953 8)	(2.668 0)
Order_num_hyear				−0.002 1	−0.000 2			−0.001 1	−0.000 3
				(−1.109 5)	(−0.485 2)			(−0.844 9)	(−0.428 9)
Reciev_addr_num				−0.272 9***	−0.158 2***			−0.231 7***	−0.139 5***
				(−8.830 2)	(−5.381 3)			(−7.403 0)	(−4.656 9)
Recieve_city_num				0.322 7***	0.257 3***			0.260 2***	0.203 4***
				(6.762 3)	(5.643 8)			(5.404 8)	(4.329 7)
Town				0.155 0**	0.124 4*			0.117 2*	0.108 6
				(2.268 3)	(1.802 7)			(1.684 1)	(1.537 5)
Recieve_phone_num				0.119 8	0.117 4			0.100 8	0.088 9
				(1.478 6)	(1.526 2)			(1.277 9)	(1.146 8)
Receiver_num				0.012 4	−0.050 2			0.021 4	−0.021 0
				(0.152 7)	(−0.656 0)			(0.274 8)	(−0.276 4)
常数项	控制	控制	控制	控制	控制	控制	控制	控制	控制
月份固定效应	控制	控制	控制	控制	控制	控制	控制	控制	控制
观测值	46 607	46 607	46 607	46 607	46 607	46 607	46 607	46 607	46 607
伪 R^2	0.050 1	0.029 2	0.078 9	0.050 0	0.104 0	0.064 1	0.115 6	0.089 2	0.135 6
AUC	0.683 0***	0.637 7***	0.730 5***	0.686 2***	0.771 4***	0.707 0***	0.783 3***	0.746 7***	0.806 4***
(SE)	0.007 0	0.007 9	0.007 5	0.007 7	0.006 8	0.006 8	0.006 0	0.006 8	0.005 7
	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)