投资组合优化中的收缩方法

赵伟皓

武汉大学经济与管理学院

2026 年 11 月 8 日

为什么投资组合优化需要收缩？

研究背景： 有限样本估计风险经均值–方差优化放大，造成投资权重不稳定及样本外表现恶化。

参数估计误差 → 优化过程放大 → 投资权重不稳定 → 样本外表现下降

收缩的基本思想： 将高估计风险的样本估计量向较稳定的目标调整，以改善样本外投资表现。[1]

$$\widehat{\theta}^{\star} = (1-\delta)\widehat{\theta} + \delta\theta_0 \quad \text{（经典线性收缩的示例）}.$$

投资组合中的主要收缩类型

收缩类型	作用对象及方法	代表文献
收益均值收缩	将样本收益均值向结构化目标收缩	Jorion (1986)
协方差矩阵收缩	调整样本协方差矩阵或其特征值	Ledoit & Wolf (2004)
权重收缩、规则结合	通过规则结合或联合估计共享信息、对冲估计误差	Kan & Zhou (2007)
联合收缩	预期收益、协方差和权重分别向某个总体水平收缩	Frost and Savarino (1986)

[1] 投资组合规则的结合也被称为一种收缩 (Lassance et al., 2024)；类别按主要作用对象或实施机制划分，彼此可能交叉。

参数层面的收缩

一、收益均值收缩

Jorion (1986), JFQA	提出 Bayes–Stein 均值收缩，降低预期收益的估计风险。
Chopra et al. (1993), MS	应用 Stein 收缩修正均值–方差输入，检验其国际资产配置价值。
DeMiguel et al. (2013), JBF	提出均值等估计量的收缩校准准则，并利用 Bootstrap 估计最优收缩强度。
Bryzgalova et al. (2025), JF	在高维资产定价中结合均值与方差收缩，构建稳健的 SDF 估计。

二、协方差矩阵收缩

Ledoit & Wolf (2004)	通过向结构化目标收缩构造稳定的线性协方差估计量。
Ledoit & Wolf (2012, 2017, 2020)	发展非线性谱收缩，并分析其高维投资组合最优性。
Kelly et al. (2026), RFS	以 Ridge 组合逼近灵活谱收缩规则，并基于样本外经济目标调参。
Lassance et al. (2025), MS revision	以预期样本外效用校准协方差收缩，同时也考虑均值估计风险。

决策层面的收缩

一、权重收缩、规则稳健收缩

Bodnar et al. (2018), EJOR	构造高维全局最小方差组合的权重收缩估计量。
Bodnar et al. (2023), IEEE TSP	向历史持仓收缩，研究动态权重估计。
Kan & Zhou (2007), JFQA	参数不确定性下的最优三基金组合规则。
Tu & Zhou (2011), JFE	通过显式组合复杂优化策略与 $1/N$ 策略，以收缩方式降低估计风险。
倪宣明等 (2021), SETP	通过多任务相关学习联合估计不同组合权重，实现类似规则稳健收缩的效果。
Kan et al. (2022), MS	无风险资产缺失下的最优组合规则。
Lassance et al. (2024), MS	考虑效用风险的稳健组合规则收缩。

二、联合收缩

Frost and Savarino (1986), JFQA	核心逻辑是利用共同结构降低有限样本噪声。
Bodnar et al. (2024), JMLR	协方差正则化与投资权重的双重收缩。
Ouyang et al. (2026), WP	将均值、协方差与投资权重收缩纳入统一框架。

Shrink with Purpose: Optimal Covariance Matrix Estimation for Portfolio Selection

Nathan Lassance, Rodolphe Vanderveken, Frederic Vrins

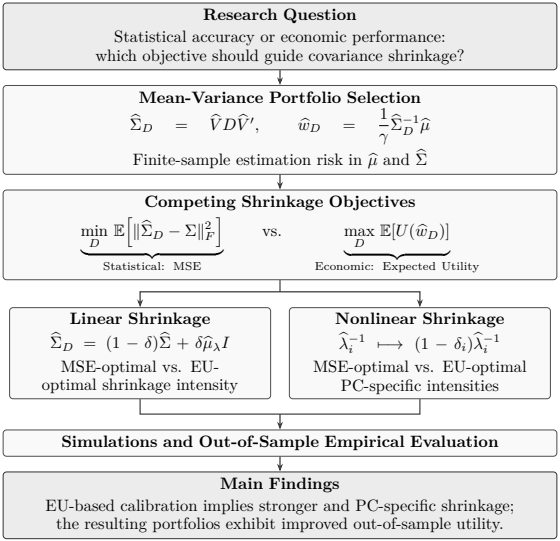
Management Science (Minor Revision)

Presenter: Weihao Zhao

School of Economics and Management, Wuhan University

11.08.2026

Framework


Research Question
Statistical accuracy or economic performance:
which objective should guide covariance shrinkage?
Mean-Variance Portfolio Selection
$\widehat{\Sigma}_D = \widehat{V} D \widehat{V}', \quad \widehat{w}_D = \frac{1}{\gamma}\widehat{\Sigma}_D^{-1}\widehat{\mu}$
Finite-sample estimation risk in $\widehat{\mu}$ and $\widehat{\Sigma}$
Competing Shrinkage Objectives
$\min_D \mathbb{E}\left[\|\widehat{\Sigma}_D - \Sigma\|_F^2\right]$
Statistical: MSE
vs.
$\max_D \mathbb{E}[U(\widehat{w}_D)]$
Economic: Expected Utility
Linear Shrinkage
$\widehat{\Sigma}_D = (1-\delta)\widehat{\Sigma} + \delta\widehat{\mu}_\lambda I$
MSE-optimal vs. EU-optimal shrinkage intensity
Nonlinear Shrinkage
$\widehat{\lambda}_i^{-1} \longmapsto (1-\delta_i)\widehat{\lambda}_i^{-1}$
MSE-optimal vs. EU-optimal PC-specific intensities
Simulations and Out-of-Sample Empirical Evaluation
Main Findings
EU-based calibration implies stronger and PC-specific shrinkage;
the resulting portfolios exhibit improved out-of-sample utility.

Why Is Shrinkage for Covariance Matrices Important?

1. **Parameter uncertainty is inherent to mean–variance portfolio choice.**
   - Expected returns and covariances are unknown and must be estimated from samples.
   - Estimation errors often ruin out-of-sample portfolio performance(DeMiguel et al., 2009).

2. **Portfolio optimization amplifies estimation errors.**
   - The plug-in portfolio depends on the inverse sample covariance matrix:

$$\widehat{\boldsymbol{w}} = \frac{1}{\gamma}\widehat{\Sigma}^{-1}\widehat{\mu} = \frac{1}{\gamma}\sum_{i=1}^{N}\frac{\widehat{v}_i^{\top}\widehat{\mu}}{\widehat{\lambda}_i}\widehat{v}_i.$$

   - Small eigenvalues can magnify noise in $\hat{\mu}$, producing extreme and unstable weights.

3. **Covariance shrinkage offers a direct way to control this instability.**
   - Linear and nonlinear shrinkage regularize sample eigenvalues, making portfolio weights less sensitive to estimation noise (Ledoit and Wolf, 2004, 2017). [2]

[2] This matters economically: unstable portfolio weights can lead to poor out-of-sample utility.

Why Shrink with Purpose?

1. **Statistical accuracy does not necessarily imply better portfolio decisions.**
   - Conventional covariance shrinkage minimizes statistical estimation losses (MSE).
   - Yet investors care about out-of-sample portfolio utility, rather than the accuracy of $\hat{\Sigma}$.

$$\underbrace{\min_D \mathbb{E}\left[\|\widehat{\Sigma}_D - \Sigma\|_F^2\right]}_{\text{Statistical objective}} \not\Longleftrightarrow \underbrace{\max_D \mathbb{E}[U(\widehat{w}_D)]}_{\text{Economic objective}} .$$

2. **Existing shrinkage criteria do not fully account for estimation risk of $\hat{\mu}$.**
   - Ledoit and Wolf (2017) establish an equivalence between statistical and utility-based optimality under **known mean returns** μ.
   - Estimation errors of $\hat{\mu}$ propagate through $\hat{\Sigma}^{-1}$ and can substantially reduce oos utility.

3. **Asymptotic shrinkage do not characterize finite-sample optimal calibration.** [3]
   - With finite samples, uncertainty in sample eigenvalues and shrinkage targets, together with estimation risk of $\hat{\mu}$, can alter the economically optimal shrinkage intensity.

[3] Conventional spectral shrinkage often relies on high-dimensional MSE criteria.

Research Questions and Hypotheses

Main Research Question

Can **utility-based covariance shrinkage** improve out-of-sample portfolio performance relative to conventional MSE-based shrinkage under parameter uncertainty?

Sub-Question	Hypothesis
RQ1: How does utility-based calibration alter the optimal linear shrinkage intensity?	**H1.** Accounting for estimation risk of $\hat{\mu}$ causes stronger covariance shrinkage than MSE-based calibration.
RQ2: Does utility-based shrinkage improve out-of-sample performance?	**H2.** EU-calibrated shrinkage delivers higher oos utility than their MSE-based counterparts.

Contribution

1. **Conventional Covariance Shrinkage**
   - **Prior:** Linear and nonlinear shrinkage under MSE-based criterion (Ledoit and Wolf 2004, 2012, 2020).
   - **Ext:** EU-based (Linear/Nonlinear) shrinkage: Optimal calibration depends not only on covariance eigenvalues, and the squared Sharpe ratio of PCs.
2. **Utility-oriented Covariance Estimation**
   - **Prior:** Bodnar et al. (2024) and Kazak et al. (2025) focus on GMV;
     Prior: Optimal result relies on that the μ is known (Ledoit and Wolf 2017).
   - **Ext:** Considering the estimation risks of μ and Σ respectively.
3. **Finite Sample MSE Shrinkage Theory**
   - **Prior:** Shrinkage considering estimation risk of eigenvalues under normal distribution (Chen et al., 2010); Shrinkage under elliptical distribution (Ollila and Raninen 2019).
   - **Ext:** Considering estimation error of t distribution and sample shrinkage target.[4]

[4] Deriving a more general finite sample optimal shrinkage strength; Providing a benchmark for comparing statistical and utility optimal shrinkage

From Estimation to Portfolio Choice

Mean–Variance Portfolio under Parameter Uncertainty

$$U(w) = w^\top \mu - \frac{\gamma}{2} w^\top \Sigma w, \qquad w^* = \frac{1}{\gamma}\Sigma^{-1}\mu, \qquad \hat{w}_D = \frac{1}{\gamma}\hat{\Sigma}_D^{-1}\hat{\mu}.$$

Spectral Covariance Shrinkage

$$\hat{\Sigma} = \hat{V}\hat{\Lambda}\hat{V}^\top, \qquad \boxed{\hat{\Sigma}_D = \hat{V} D \hat{V}^\top.}$$

- Preserve sample eigenvectors and adjust eigenvalues through the diagonal matrix D.
- The shrinkage parameters determine the covariance estimator used for portfolio allocation.

Utility-based Objective

$$\boxed{\max_D \; EU(\hat{w}_D) = \max_D \; \mathbb{E}\left[\hat{w}_D^\top \mu - \frac{\gamma}{2}\hat{w}_D^\top \Sigma \hat{w}_D\right].}$$

- Calibrate covariance shrinkage to expected oos utility, rather than estimation accuracy.

Linear Shrinkage: MSE vs. EU Calibration

$$\hat{\Sigma}_\delta = (1-\delta)\hat{\Sigma} + \delta\hat{\mu}_\lambda I_N, \qquad \hat{\mu}_\lambda = \frac{1}{N}\operatorname{tr}(\hat{\Sigma}).$$

1. MSE-Optimal Shrinkage — Statistical Accuracy

$$\delta^*_{\text{mse}} = \arg\min_\delta \tfrac{1}{N}\mathbb{E}\left[\|\hat{\Sigma}_\delta - \Sigma\|_F^2\right], \qquad \delta^*_{\text{mse}} = \frac{B}{Ns+B}.$$

- $B = B(N, T, s, \kappa)$; s measures eigenvalue dispersion and κ captures tail kurtosis.[5]

2. EU-Optimal Shrinkage — Portfolio Utility

$$\delta^*_{\text{eu}} = \arg\max_\delta EU(\hat{w}_\delta), \qquad EU(\hat{w}_\delta) = C_1 f(\delta)^\top \theta^2_{PC} - C_2 f(\delta)^\top A f(\delta).$$

$$f_i(\delta) = \tfrac{\lambda_i}{(1-\delta)\lambda_i + \delta\mu_\lambda}, \qquad \theta^2_{PC,i} = \frac{(v_i^\top \mu)^2}{\lambda_i}.$$

- Additionally depends on **PC squared Sharpe ratios** and estimation-risk parameters. [6]

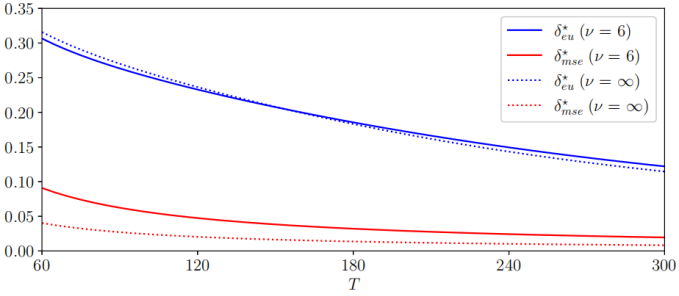
Key Innovation: Incorporating estimation risk of $\hat{\mu}$ beyond covariance estimation error.

[5] Optimal calibration depends on covariance structure, and **excludes expected returns** $\hat{\mu}$.

[6] Accounts for estimation errors of $\hat{\mu}$ propagated through portfolio weights.

Linear Shrinkage: Calibration Implications

RQ1: How does estimation risk of $\hat{\mu}$ alter the optimal linear shrinkage intensity?



$$\delta^{*}_{\text{mse}} = 0.05 \quad < \quad \delta^{*}_{\text{eu}} = 0.24, \qquad (T = 120,\ \nu = 6).$$

- EU calibration requires nearly five times stronger shrinkage in this setting.[7]
- The result highlights the importance of estimation risk of $\hat{\mu}$ for shrinkage calibration.

[7] $N = 25$; $T \in [60, 300]$; $\nu \in \{6, \infty\}$. Figure 1 reports oracle intensities under calibrated population parameters.

Nonlinear Shrinkage: MSE vs. EU Calibration

From Linear to Nonlinear Shrinkage

- Linear: one common intensity δ; **Nonlinear**: PC-specific intensities $\boldsymbol{\delta} = (\delta_1, \ldots, \delta_N)^\top$. $\frac{1}{\lambda_i} \longmapsto \frac{1-\delta_i}{\lambda_i}$

---

1. MSE-Optimal Nonlinear Shrinkage

$$\boxed{\delta^*_{\text{mse},i} = \frac{a(\mu_\lambda - \lambda_i)}{a\mu_\lambda + \lambda_i},} \qquad a = \frac{1}{T-1} + \frac{2\kappa}{T}$$

- Depends on **eigenvalues** λ_i, sample size T, and kurtosis κ; independent of expected returns μ.
- Lower-variance PCs receive stronger shrinkage; $\delta^*_{\text{mse},i} < 0$ when $\lambda_i > \mu_\lambda$.

---

2. EU-Optimal Nonlinear Shrinkage

$$\boxed{\delta^*_{\text{eu},i} = 1 - C(R_i - \frac{N}{T-2}\bar{R})} \qquad R_i = \frac{k_1\theta^2_{PC,i}}{k_2\theta^2_{PC,i} + k_3/T}, \qquad C = \frac{(T-N-1)(T-N-4)}{(T-1)(T-N-2)}. \qquad \theta^2_{PC,i} = \frac{(v_i^\top \mu)^2}{\lambda_i}.$$

- Depends on **PC squared SRs**, (N, T), and finite-sample and distributional adjustment factors (k_1, k_2, k_3).
- Lower-Sharpe-ratio PCs receive stronger shrinkage; $\delta^*_{\text{eu},i} \geq 0$.

Key Innovation: EU-based calibration shifts the shrinkage criterion from **eigenvalues** λ_i to **risk-adjusted return signals**, while accounting for estimation risk of $\hat{\mu}$.

Net out-of-sample utility (in %)

RQ2: Does utility-based covariance shrinkage improve out-of-sample portfolio utility?

Portfolio	$\hat{\boldsymbol{\Sigma}}_D$	$T = 120$	
		25SBM	**10MOM**
MV	EUL	9.12	10.1
MV	EUNL	**9.36**	**11.0**
MV	MSEL	−8.75	4.00
MV	MSENL	−1.93	6.12
GMV	LW2004	6.59	5.66
MV	LW2020	−45.5	−7.32
MV	PCA	1.90	7.79
MV	UPSA	3.00	−0.22

- **EUL > MSEL:** Utility gains of 17.87 and 6.10 percentage points.
- **EUNL > MSENL:** Utility gains of 11.29 and 4.88 percentage points.

为什么具备发表于 *MS* 的潜力？

1. **研究问题：从统计精度转向决策质量**
   - 揭示协方差估计的统计最优与投资组合效用最优之间的差异，回应从“Predict-then-Optimize” 到 “Predict-and-Optimize” 的研究范式转变。

2. **边际创新：最优收缩准则**
   - 将收益均值估计风险纳入协方差收缩的效用目标，不再仅依据协方差估计误差确定最优收缩强度。

3. **理论机制具有经济解释**
   - 建立有限样本线性与非线性收缩框架；揭示最优收缩与主成分平方夏普比率之间的联系，解释为何效用导向收缩通常更强。

4. **实证证据：理论与实际决策相结合**
   - 通过模拟及六组真实资产组合数据、21 种策略比较，展示样本外净效用改善，并提供稳健性检验。

Table 3 复现：实证设定

数据使用 Kenneth French Data Library 的月度价值加权组合收益，并减去同期无风险利率。

数据集	资产数	样本区间	样本外月份
25SBM（规模与账面市值比）	25	1926-07 至 2024-07	1,057
10MOM（动量）	10	1927-01 至 2024-07	1,051

滚动样本外检验

- 每月使用过去 $T = 120$ 个月估计权重，并持有一个月。
- 风险厌恶系数固定为 $\gamma = 3$。每次调仓取单边 10 bp 比例交易成本。
- 首个样本外月不收取交易成本。随后按风险资产目标权重的月度变化计算换手率。

$$r_t^{\text{net}} = (1 + r_t^{\text{gross}})(1 - 0.001\,\text{TO}_t) - 1, \qquad \widehat{U} = 12\left(\bar{r}^{\text{net}} - \frac{\gamma}{2} s^2_{r^{\text{net}}}\right).$$

核心均值–方差策略

$\gamma = 3$，$T = 120$

	原文		复现	
策略	25SBM	10MOM	25SBM	10MOM
EUL	9.12	10.10	8.86 (−0.26)	9.86 (−0.24)
EUNL	9.36	11.00	10.22 (+0.86)	11.88 (+0.88)
MSEL	−8.75	4.00	−9.04 (−0.29)	4.41 (+0.41)
MSENL	−1.93	6.12	−2.12 (−0.19)	6.55 (+0.43)
SAMPLE	−109.00	−14.90	−109.81 (−0.81)	−15.57 (−0.67)
LW2004	−8.68	4.33	−9.62 (−0.94)	4.47 (+0.14)
LW2020	−45.50	−7.32	−46.05 (−0.55)	−7.32 (+0.00)

- 数值为百分比年化净样本外效用。
- 复现值后的括号为复现减原文，单位是百分点（pp）。
- 核心策略的比较中，最大绝对差异为 0.94 个百分点。

基准与外部策略

$\gamma = 3$，$T = 120$

	原文		复现	
策略	25SBM	10MOM	25SBM	10MOM
GMV–SAMPLE	6.15	5.42	6.12 (−0.03)	5.87 (+0.45)
GMV–LW2004	6.59	5.66	6.57 (−0.02)	5.92 (+0.26)
GMV–SSHH	6.52	5.54	6.44 (−0.08)	5.87 (+0.33)
GMVRF–SAMPLE	7.59	4.48	7.63 (+0.04)	4.99 (+0.51)
GMVRF–LW2004	6.60	4.45	6.36 (−0.24)	4.88 (+0.43)
GMVRF–SSHH	7.49	4.47	7.30 (−0.19)	4.96 (+0.49)
EW	4.65	3.48	4.68 (+0.03)	3.47 (−0.01)
EWRF	2.91	2.31	2.92 (+0.01)	2.27 (−0.04)
UPSA	3.00	−0.22	7.87 (+4.87)	5.37 (+5.59)
PCA	1.90	7.79	−94.64 (−96.54)	−6.59 (−14.38)

- 数值为百分比年化净样本外效用。
- 复现值后的括号为复现减原文，单位是百分点（pp）。
- 除 PCA 与 UPSA 外，最大绝对差异为 0.51 个百分点。

组合基准与外部方法实现

均值–方差与 GMV 基准

$$\widehat{w}(\widehat{\Sigma}) = \frac{1}{\gamma}\widehat{\Sigma}^{-1}\widehat{\mu}, \qquad \widehat{w}_{\mathrm{GMV}} = \frac{\widehat{\Sigma}^{-1}\mathbf{1}}{\mathbf{1}'\widehat{\Sigma}^{-1}\mathbf{1}}.$$

其中 $\widehat{\Sigma}$ 分别取 SAMPLE、LW2004 或 SSHH。含无风险资产时：

$$\widehat{w}_{\mathrm{GMVRF}} = c_T \frac{\mathbf{1}'\widehat{\Sigma}^{-1}\widehat{\mu}}{\mathbf{1}'\widehat{\Sigma}^{-1}\mathbf{1}}\widehat{\Sigma}^{-1}\mathbf{1},$$

$$c_T = \frac{\widehat{\eta}(T-N-1)(T-N-4)}{\gamma\widehat{\phi}T(T-2)}.$$

简单规则与外部方法

$$w_{\mathrm{EW}} = \frac{1}{N}\mathbf{1}, \qquad \widehat{w}_{\mathrm{EWRF}} = \frac{T-3}{\gamma T}\frac{w'_{\mathrm{EW}}\widehat{\mu}}{w'_{\mathrm{EW}}\widehat{\Sigma}w_{\mathrm{EW}}}w_{\mathrm{EW}}.$$

PCA 只保留前 $\widehat{K}$ 个主成分：

$$\widehat{w}_{\mathrm{PCA}} = \frac{1}{\gamma}\widehat{V}_{\widehat{K}}\widehat{\Lambda}_{\widehat{K}}^{-1}\widehat{V}'_{\widehat{K}}\widehat{\mu}.$$

UPSA 组合一组岭回归方向：

$$\widehat{w}_{\mathrm{UPSA}} \propto \sum_{\ell} a_\ell(\widehat{\Sigma} + \lambda_\ell I)^{-1}\widehat{\mu}, \qquad a_\ell \geq 0,$$

权重 a_ℓ 通过留一法效用准则确定。

PCA 的因子数实现与 UPSA 的公开代码版本均会显著影响最终结果。

从组合规则收缩到多任务相关学习

研究出发点：样本均值–方差（MV）组合对参数估计误差敏感；全局最小方差（GMV）组合不依赖均值估计。不同投资规则具有互补信息，能否通过结合降低估计风险？

一、传统思路：先分别估计，再显式组合投资规则

$$\widehat{\boldsymbol{w}}_{\text{comb}} = (1-\delta)\widehat{\boldsymbol{w}}_{\text{MV}} + \delta\widehat{\boldsymbol{w}}_{\text{GMV}}, \qquad 0 \le \delta \le 1.$$

- 通过调整不同投资规则的配置比例，对冲部分权重估计误差。
- 经典规则组合通常需要对收益分布作出假设，以确定最优组合系数。[8]

⇓

二、倪宣明等（2021）：从事后收缩转向相关任务的联合估计

$$\boldsymbol{W} = [\boldsymbol{w}_{\text{MV}}, \boldsymbol{w}_{\text{GMV}}], \qquad \boldsymbol{\Omega}: \text{ 两个任务之间的相关性矩阵.}$$

- 运用**多任务相关学习（MTRL）**，同时估计 MV 与 GMV 组合权重。
- 学习任务间的相关结构，在权重估计阶段实现信息共享，从而取得**类似规则加权的稳健化效果**。

MTRL 不是将两个已估计组合直接作线性凸组合；其与规则收缩的联系在于跨规则信息共享与关联正则化。

[8] Kan and Zhou (2007) 研究三基金配置；Tu and Zhou (2011) 研究优化策略与 $1/N$ 组合的加权。

MTRL-MV：利用策略相关性控制估计风险

一、核心方法：联合估计 MV 与 GMV 权重，并学习任务相关结构

$$\min_{W,\Omega} \underbrace{-\widehat{\mu}^\top w_1 + w_1^\top \widehat{\Sigma} w_1}_{\text{MV 任务损失}} + \underbrace{w_2^\top \widehat{\Sigma} w_2}_{\text{GMV 任务损失}} + \underbrace{\frac{\lambda_1}{2}\operatorname{tr}(WW^\top)}_{\text{权重规模惩罚}} + \underbrace{\frac{\lambda_2}{2}\operatorname{tr}(W\Omega^{-1}W^\top)}_{\text{任务关联惩罚}},$$

$$\text{s.t.} \quad w_j \geq 0, \quad \mathbf{1}^\top w_j = 1 \ (j = 1, 2), \quad \Omega \succeq 0, \quad \operatorname{tr}(\Omega) = 1.$$

- λ_1 控制两组权重的整体规模；$\lambda_2 \operatorname{tr}(W\Omega^{-1}W^\top)/2$ 通过任务相关性约束两组权重，在估计过程中共享信息。

二、样本外结果：（中国 A 股特征排序组合）

数据集	指标	MTRL-MV	MV	TZ	BS
S2BM3	SR	0.0711	0.0748	0.0477	0.0724
	Turnover	**0.5646**	0.6040	0.3947	0.6404
S11BM11	SR	**0.0859**	0.0755	0.0448	0.0808
	Turnover	1.0588	1.2511	0.5643	1.2165

估计风险如何影响最优策略收缩？

潜在 idea：不同投资规则的估计风险与误差相关性，如何共同决定最优组合比例？

$$\widehat{\boldsymbol{w}}_\lambda = (1-\lambda)\widehat{\boldsymbol{w}}_A + \lambda\widehat{\boldsymbol{w}}_B, \qquad 0 \le \lambda \le 1.$$

一、不同机器学习策略的联合信息（如 RF + NN）

- 两种学习规则可能具有不同的配置偏差与估计误差；关注其**决策估计误差的交叉相关性**。
- 估计误差不完全同步时，策略组合可能分散部分估计风险；高度相关时，组合收益可能有限。

二、复杂 ML 策略向简单规则收缩（如 RFF + $1/N$）

- 简单策略提供稳定参照，减少对复杂 ML 估计噪声的暴露，但可能损失其有效收益信号。
- 核心是平衡 **复杂模型的增量经济价值**与 **决策估计风险**，确定最优 λ。

统一经济机制：在真实 μ, Σ 固定的均值–方差效用下，

$$\mathbb{E}_{\mathcal{D}}[U(\widehat{w}_\lambda)] = U((1-\lambda)\bar{w}_A + \lambda\bar{w}_B) - \frac{\gamma}{2}\underbrace{\left[(1-\lambda)^2 R_A + \lambda^2 R_B + 2\lambda(1-\lambda)R_{AB}\right]}_{\text{组合的决策估计风险}}.$$

其中 $\bar{w}_j = \mathbb{E}_{\mathcal{D}}[\widehat{w}_j]$，$R_j = \mathrm{tr}(\Sigma\,\mathrm{Var}_{\mathcal{D}}(\widehat{w}_j))$，$R_{AB} = \mathrm{tr}(\Sigma\,\mathrm{Cov}_{\mathcal{D}}(\widehat{w}_A, \widehat{w}_B))$。

固定基准的特例：若 $\widehat{w}_A = w_0 = 1/N$，则 $R_A = R_{AB} = 0$，仅剩复杂策略的估计风险 $\lambda^2 R_B$。

$$\lambda^* = \Pi_{[0,1]}\left[\frac{d^\top(\mu - \gamma\Sigma w_0)}{\gamma(d^\top\Sigma d + R_B)}\right], \qquad d = \bar{w}_B - w_0.$$

后续切入点：刻画模型复杂度与联合决策估计风险的关系，并据此构造**效用导向的可行收缩系数**。

联合决策估计风险如何影响策略收缩？

一、两种投资规则的权重估计风险

$\widehat{w}_j = \bar{w}_j + \varepsilon_j$，$\bar{w}_j = \mathbb{E}_{\mathcal{D}}[\widehat{w}_j]$，$\mathbb{E}_{\mathcal{D}}[\varepsilon_j] = 0$（$j = A, B$）；组合规则为 $\widehat{w}_\lambda = (1-\lambda)\widehat{w}_A + \lambda\widehat{w}_B$。

$$R_A = \mathbb{E}_{\mathcal{D}}[\varepsilon_A^\top \Sigma \varepsilon_A], \qquad R_B = \mathbb{E}_{\mathcal{D}}[\varepsilon_B^\top \Sigma \varepsilon_B],$$

$$R_{AB} = \mathbb{E}_{\mathcal{D}}[\varepsilon_A^\top \Sigma \varepsilon_B].$$

R_A, R_B：各自的风险加权**权重估计方差**；R_{AB}：两种规则的**估计误差交叉关系**（可正、可负）。其中 Σ 为资产收益协方差矩阵。

二、期望效用：平均配置价值 − 联合决策估计风险

$$\mathbb{E}_{\mathcal{D}}[U(\widehat{w}_\lambda)] = \underbrace{U((1-\lambda)\bar{w}_A + \lambda\bar{w}_B)}_{\text{平均配置的效用}} - \frac{\gamma}{2}\underbrace{\left[(1-\lambda)^2 R_A + \lambda^2 R_B + 2\lambda(1-\lambda)R_{AB}\right]}_{R(\lambda)\text{: 组合的决策估计风险}}.$$

数值例子：若 $R_A = R_B = 1$，$\lambda = 1/2$，则 $R(1/2) = 0.5 + 0.5R_{AB}$：

估计误差关系	同向（$R_{AB} = 1$）	不相关（$R_{AB} = 0$）	反向（$R_{AB} = -1$）
组合估计风险 $R(1/2)$	1	0.5	0

含义：即使两种规则自身都不稳定，估计误差不完全同向时，组合仍可能分散估计风险。

三、两类拓展：ML + ML 关注 R_A, R_B, R_{AB} 的联合作用；ML + 固定 $1/N$ 时，$R_A = R_{AB} = 0$，仅剩 $R(\lambda) = \lambda^2 R_B$。

经济学问题：最优收缩比例应如何权衡复杂策略的平均经济价值与联合估计风险？

MSE 与 EU 导向收缩的经济含义

1. 两种优化准则的核心区别

	MSE 导向	**EU 导向**
线性收缩	$\delta^*_{\text{mse}} = \dfrac{B}{Ns+B}$ **统计精度**：依据协方差特征值的离散程度、样本量和峰度；不依赖预期收益 μ。	$\delta^*_{\text{eu}} = \arg\max_{\delta} EU(\hat{w}_\delta)$ **投资效用**：额外考虑主成分的收益信号，以及样本均值估计误差对组合效用的影响。
非线性收缩	$\delta^*_{\text{mse},i} = \dfrac{a(\mu_\lambda - \lambda_i)}{a\mu_\lambda + \lambda_i}$ **依据 PC 方差**：$\lambda_i = \text{Var}(v_i^\top r)$，衡量主成分方向的风险尺度；低方差 PC 受到更强的逆特征值收缩。	$\delta^*_{\text{eu},i} = 1 - C(R_i - b\bar{R})$ **依据 PC 平方夏普比率**：$\theta^2_{PC,i} = (v_i^\top \mu)^2/\lambda_i$，衡量风险调整后的收益信号；低平方夏普比率 PC 受到更强收缩。

2. 示例：小特征值不一定意味着应当更强收缩

主成分特征	PC A	PC B
方差 λ_i	0.01	0.08
平方夏普比率 $\theta^2_{PC,i}$	0.20	0.01

- **MSE 导向**：$\lambda_A < \lambda_B \Rightarrow \delta^*_{\text{mse},A} > \delta^*_{\text{mse},B}$。
  PC A 方差较小，因此逆特征值受到更强收缩；重点是修正协方差矩阵的风险结构。
- **EU 导向**：$\theta^2_{PC,A} > \theta^2_{PC,B} \Rightarrow \delta^*$

MSE–最优线性收缩

线性收缩估计器

$$\hat{\Sigma}_\delta = (1-\delta)\hat{\Sigma} + \delta\hat{\mu}_\lambda I_N, \qquad \hat{\mu}_\lambda = \tfrac{1}{N}\operatorname{tr}(\hat{\Lambda}).$$

Proposition 2: 有限样本 MSE–最优收缩强度

$$\boxed{\delta^*_{\text{mse}} = \frac{\dfrac{(N-2)s+N+2}{T-1} + \dfrac{\kappa[2(N-1)s+N+2]}{T}}{Ns + \dfrac{(N-2)s+N+2}{T-1} + \dfrac{\kappa[2(N-1)s+N+2]}{T}}.}$$

其中，球形度参数 s 定义为

$$\boxed{s = \frac{N\operatorname{tr}(\Lambda^2)/[\operatorname{tr}(\Lambda)]^2 - 1}{N-1} \in [0,1).}$$

- $s = 0$ 若所有总体特征值相等；那么 $\delta^*_{\text{mse}} = 1$。
- κ 刻画椭圆峰度; $\kappa = 0$ 时退化为多元正态分布。
- 对于有限样本 T，$\delta^*_{\text{mse}} > 0$，且不依赖 μ.
- 相对于以前的结果，在椭圆收益分布下，估计量解释了 $\hat{\mu}_\lambda$ 的抽样误差。

EU–最优线性收缩

样本外期望效用

对于 $T \geq N+5$，在命题 3 规定的分配近似下，

$$EU(\hat{w}_D) = \frac{k_1(T-1)}{\gamma(T-N-2)} f(\delta)^\top \theta^2_{PC} - \frac{(T-1)^2}{2\gamma(T-N-2)(T-N-4)} f(\delta)^\top A f(\delta).$$

关键符号

$$f_i(\delta) = \frac{\lambda_i}{(1-\delta)\lambda_i + \delta\mu_\lambda}, \qquad \theta^2_{PC,i} = \frac{(v_i^\top \mu)^2}{\lambda_i}.$$

$$A_{ij} = \left(k_2\theta^2_{PC,i} + \frac{k_3}{T}\right)\left(\mathbb{I}_{\{i=j\}} + \frac{\mathbb{I}_{\{i\neq j\}}}{T-N-1}\right).$$

这里，$k1$ $k2$ $k3$ 捕获了估计风险和椭圆收益分布的影响 (Lassance et al., 2025)。

最优收缩强度 $\delta^*_{\text{eu}} = \arg\max_{\delta\in\mathbb{R}} EU(\hat{w}_D).$

目标有一个解析表达式，δ^*_{eu} 是通过数值得到的。

- EU 最优校准取决于协方差特征值和 PC 平方夏普比。
- 它考虑了均值估计误差对投资组合效用的影响。
- EU 公式依赖于收缩协方差估计的抽样分布的保守近似。

MSE 最优非线性收缩的经济含义

1. 最优强度取决于特征值相对平均水平的偏离

$$\delta^*_{\mathrm{mse},i} = \frac{a(1-x_i)}{a+x_i} \qquad x_i = \frac{\lambda_i}{\mu_\lambda}, \qquad a = \frac{1}{T-1} + \frac{2\kappa}{T}.$$

- x_i 衡量第 i 个主成分方差相对于总体平均特征值的大小。
- a 反映样本量及椭圆分布尾部峰度的影响。
- 固定其他条件，$\dfrac{\partial \delta^*_{\mathrm{mse},i}}{\partial x_i} = -\dfrac{a(1+a)}{(a+x_i)^2} < 0$。

2. 特征值位置决定逆特征值的调整方向

相对方差	最优收缩强度	对逆特征值的影响
$x_i < 1$	$\delta_i^* > 0$	向零收缩；提高调整后的协方差特征值。
$x_i = 1$	$\delta_i^* = 0$	不调整该方向的逆特征值。
$x_i > 1$	$\delta_i^* < 0$	放大逆特征值；降低调整后的协方差特征值。

3. 为什么需要迹保持约束？

- 线性收缩天然保持矩阵的迹；非线性收缩一般不满足这一性质。
- Proposition 4 要求 $\mathbb{E}[\mathrm{tr}(\hat{\Sigma}_D)] = \mathbb{E}[\mathrm{tr}(\hat{\Sigma})]$。
- Remark 7：无约束 MSE 最优强度可能发散；迹约束改善解的稳定性。

核心结论： MSE 准则根据主成分方差相对于平均方差的偏离，调整协方差谱结构；不直接考虑预期收益信号。

EU 最优收缩与均值估计风险

1. 即便已知协方差矩阵，仍然需要收缩

- 假设总体协方差矩阵 Σ 已知，但收益均值仍由样本估计（$\hat{\mu}$ ）。
- **MSE 准则**：协方差没有估计误差，因此 $\delta^*_{\text{mse},i} = 0$。
- **EU 准则**：令 $q_i = 1 - \delta_i$，第 i 个主成分的预期效用贡献为

$$EU_i(q_i) = \frac{1}{\gamma}\left[q_i\theta^2_{PC,i} - \frac{q_i^2}{2}\left(\theta^2_{PC,i} + \frac{1}{T}\right)\right].$$

$$q_i^* = \frac{\theta^2_{PC,i}}{\theta^2_{PC,i} + 1/T}, \qquad \delta^*_{\text{eu},i} = \frac{1/T}{\theta^2_{PC,i} + 1/T} > 0$$

解释：即使协方差已知，均值估计噪声仍然存在。低平方夏普比率的主成分需要更强的收缩。

---

2. 一般椭圆分布下的 EU 最优收缩

$$R_i = \frac{k_1\theta^2_{PC,i}}{k_2\theta^2_{PC,i} + k_3/T}, \qquad \delta^*_{\text{eu},i} = 1 - C\left(R_i - \frac{N}{T-2}\bar{R}\right).$$

- $\theta^2_{PC,i}$：主成分收益信号；k_1, k_2, k_3：有限样本与分布修正系数。
- 因 R_i 随平方夏普比率上升而增大，故低平方夏普比率的 PC 收缩更强。

从 Oracle 最优收缩到可实施估计

核心问题：线性与非线性的理论最优收缩强度依赖未知参数 μ, Σ 及椭圆分布特征，需通过样本估计将其转化为可实施收缩强度。

1. MSE 最优收缩：估计协方差结构及峰度

未知总体参数	数据驱动估计方法
峰度 κ	利用各资产样本四阶矩，构造经有限样本偏差修正的峰度估计 $\hat{\kappa}$。（29）
球形度 s	采用渐近无偏估计量 $\hat{s}$，根据样本特征值与 $\hat{\kappa}$ 修正；将结果截断至 $[0,1]$。（30）
总体特征值 λ_i	利用 MSE 最优线性收缩估计：$\hat{\lambda}_{i,\mathrm{mse}} = (1-\hat{\delta}_{\mathrm{mse}})\hat{\lambda}_i + \hat{\delta}_{\mathrm{mse}}\hat{\mu}_{\lambda}$。（31）

2. EU 最优收缩：进一步估计收益信号与分布修正参数

未知总体参数	数据驱动估计方法
PC 平方夏普比率 $\theta^2_{PC,i}$	假设平方夏普比率按主成分序号几何递减：$\hat{\theta}^2_{PC,i} = \hat{g}^{\,i-1}\hat{\theta}^2_{a,PC1}$。利用 Kan–Zhou 调整估计量估计总体平方夏普比率 θ^2 和第一主成分的平方夏普比率，再确定 $\hat{g}$。
分布修正系数 k_1, k_2, k_3	高维渐近 $(k_1,k_2,k_3) \approx (\eta,\phi,\eta)$。先从样本收益估计椭圆分布尺度变量 $\hat{\tau}_t$，再计算 $\hat{\eta}, \hat{\phi}$。

3. 代入最优收缩规则，构造投资组合

- **MSE：**将 $\hat{\kappa}, \hat{s}, \hat{\lambda}_i$ 代入 Propositions 2、4，计算收缩强度。
- **EU：**进一步代入 $\hat{\theta}^2_{PC,i}$ 及 $(\hat{\eta}, \hat{\phi}, \hat{\eta})$；线性 EU 数值优化，非线性 EU 利用闭式解。

线性谱收缩与非线性谱收缩

谱收缩（spectral shrinkage）的共同特征：保留样本特征向量，仅调整特征值：

$$\widehat{\Sigma} = \widehat{V}\,\mathrm{diag}(\widehat{\lambda}_1, \ldots, \widehat{\lambda}_N)\widehat{V}^\top, \quad \widehat{\Sigma}_{\mathrm{sh}} = \widehat{V}\,\mathrm{diag}(\widetilde{\lambda}_1, \ldots, \widetilde{\lambda}_N)\widehat{V}^\top.$$

例子：设三个样本特征值为 $\widehat{\boldsymbol{\lambda}} = (7, 4, 1)$，共同收缩目标为 $\bar{\lambda} = 4$。

1. 线性谱收缩：所有方向使用同一强度 $\delta = 0.5$。

$$\widetilde{\lambda}_i^{\mathrm{L}} = (1-\delta)\widehat{\lambda}_i + \delta\bar{\lambda}, \qquad (7, 4, 1) \longrightarrow (5.5, 4, 2.5).$$

2. 非线性谱收缩：不同特征值可采用不同强度；例如 $\boldsymbol{\delta} = (0.6, 0, 0.8)$。

$$\widetilde{\lambda}_i^{\mathrm{NL}} = (1-\delta_i)\widehat{\lambda}_i + \delta_i\bar{\lambda}, \qquad (7, 4, 1) \longrightarrow (5.2, 4, 3.4).$$

	PC1	PC2	PC3
样本特征值 $\widehat{\lambda}_i$	7	4	1
线性收缩 $\widetilde{\lambda}_i^{\mathrm{L}}$	5.5	4	2.5
非线性收缩 $\widetilde{\lambda}_i^{\mathrm{NL}}$	5.2	4	3.4

概念区分：“谱收缩”指**保留特征方向**；“线性 / 非线性”指**特征值调整规则**。向 $\bar{\lambda}I$ 的线性收缩也是谱收缩。

Shrink with Purpose 第 4 节采用的是逆特征值收缩 $\widehat{\lambda}_{D,i}^{-1} = (1-\delta_i)\widehat{\lambda}_i^{-1}$，与本例的共同目标形式不同。

主成分、特征值与协方差谱收缩

1. **协方差矩阵的特征值分解** $\Sigma = V\Lambda V^\top, \qquad \Lambda = \mathrm{diag}(\lambda_1, \ldots, \lambda_N).$
   - v_i：第 i 个单位特征向量，决定主成分的资产组合方向。
   - $PC_{i,t} = v_i^\top r_t$：第 i 个主成分的收益（资产收益的线性组合）。
   - λ_i：第 i 个主成分收益的方差，衡量该方向的风险大小。

2. **为什么特征值等于主成分收益方差？** $\mathrm{Var}(PC_i) = \mathrm{Var}(v_i^\top r) = v_i^\top \Sigma v_i \quad = \lambda_i v_i^\top v_i = \lambda_i.$
   - 不同主成分的收益互不相关：$\mathrm{Cov}(PC_i, PC_j) = 0$，$i \neq j$。
   - λ_i 是**主成分方差**，一般不等于某只原始资产的收益方差 Σ_{ii}。

3. **两资产示例：共同波动与相对波动**

$$\Sigma = \begin{pmatrix} 0.04 & 0.018 \\ 0.018 & 0.04 \end{pmatrix}, \qquad V = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}, \qquad \Lambda = \begin{pmatrix} 0.058 & 0 \\ 0 & 0.022 \end{pmatrix}.$$

   - $PC_1 = (r_A + r_B)/\sqrt{2}$：同向波动，方差为 0.058。
   - $PC_2 = (r_A - r_B)/\sqrt{2}$：相对波动，方差为 0.022。

4. **与本文谱收缩的关系** $\hat{\Sigma}_D = \hat{V} D \hat{V}^\top, \qquad D = \mathrm{diag}(d_1, \ldots, d_N).$
   - 保持样本特征向量 $\hat{V}$ 不变，将原始样本特征值 $\hat{\lambda}_i$ 调整为 d_i。
   - 因 $\hat{w}_D = \gamma^{-1} \hat{\Sigma}_D^{-1} \hat{\mu}$，调整 d_i 可以改变各主成分对投资权重的影响。

EU 最优收缩如何控制参数估计风险？

1. **控制收益均值估计误差向投资权重的传导**
   - **误差传播**：设 $\hat{\mu} = \mu + \varepsilon_\mu$，则估计权重可分解为

$$\hat{w}_D = \underbrace{\frac{1}{\gamma}\hat{\Sigma}_D^{-1}\mu}_{\text{收益信号对应的权重}} + \underbrace{\frac{1}{\gamma}\hat{\Sigma}_D^{-1}\varepsilon_\mu}_{\text{均值估计误差的传导}} .$$

   - 通过调整 $\hat{\Sigma}_D^{-1}$，也可以抑制均值估计误差在投资权重中的放大。

2. **进一步考虑样本特征值的估计误差**
   - **线性收缩**：传统理论使用总体收缩目标 $\mu_\lambda = N^{-1}\operatorname{tr}(\Lambda)$；本文考虑样本目标从而考虑收缩目标自身的估计误差。

$$\hat{\mu}_\lambda = \frac{1}{N}\operatorname{tr}(\hat{\Lambda}), \qquad \hat{\Sigma}_\delta = (1-\delta)\hat{\Sigma} + \delta\hat{\mu}_\lambda I_N,$$

   - **非线性收缩**：传统方法直接校准 $D = \operatorname{diag}(d_1, \ldots, d_N)$；本文设定

$$D = (I_N - \Delta)^{-1}\hat{\Lambda}, \qquad d_i = \frac{\hat{\lambda}_i}{1-\delta_i},$$

   使样本特征值的随机性显式进入收缩矩阵。

样本平均特征值与有限样本 MSE 最优收缩

1. **收缩目标本身存在估计误差**
   - 总体平均特征值 μ_λ 未知，实际使用样本平均特征值 $\hat{\mu}_\lambda$：

$$\mu_\lambda = \frac{1}{N}\operatorname{tr}(\Sigma), \qquad \hat{\mu}_\lambda = \frac{1}{N}\operatorname{tr}(\hat{\Sigma}).$$

   - 线性收缩估计量为

$$\boxed{\hat{\Sigma}_\delta = (1-\delta)\hat{\Sigma} + \delta\hat{\mu}_\lambda I_N.}$$

   - $\hat{\Sigma}$ 和 $\hat{\mu}_\lambda$ 均由有限样本估计，因此收缩矩阵同时受到二者抽样误差的影响。

2. **Proposition 2：有限样本 MSE 最优收缩**
   - 在多元椭圆分布下，最小化 $\mathbb{E}\|\hat{\Sigma}_\delta - \Sigma\|_F^2/N$，得到 $\boxed{\delta^*_{\text{mse}} = \dfrac{B}{Ns+B}}$
   - s 衡量总体特征值离散程度；κ 为椭圆分布峰度参数。最优强度不依赖收益均值 μ。

3. **相对于已有研究的边际拓展**
   - Chen et al. (2010)：样本收缩目标 $\hat{\mu}_\lambda$，但假设多元正态分布。
   - Ollila and Raninen (2019)：允许多元椭圆分布，但考虑总体收缩目标 μ_λ。
   - **本文**：在多元椭圆分布与有限样本设定下，推导考虑随机收缩目标 $\hat{\mu}_\lambda$ 的 MSE 最优强度。

注：$\hat{\mu}_\lambda$ 不同于收益样本均值向量 $\hat{\mu}$；此处讨论的是收缩估计量本身的随机性，而非收益均值估计误差对投资效用的影响。

MTRL-MV 的目标函数与求解流程

1．两个相关任务与联合目标函数

设 $W=[w_1,w_2]$，$w_1=w_{\mathrm{MV}}$，$w_2=w_{\mathrm{GMV}}$；$\Omega\in\mathbb{R}^{2\times2}$ 为待学习的任务相关性矩阵。

$$\min_{W,\Omega}\ \underbrace{-\widehat{\mu}^{\top}w_1+w_1^{\top}\widehat{\Sigma}w_1}_{\text{MV 任务损失}}+\underbrace{w_2^{\top}\widehat{\Sigma}w_2}_{\text{GMV 任务损失}}+\underbrace{\frac{\lambda_1}{2}\operatorname{tr}(WW^{\top})}_{\text{权重规模惩罚}}+\underbrace{\frac{\lambda_2}{2}\operatorname{tr}(W\Omega^{-1}W^{\top})}_{\text{任务关联惩罚}},$$

$$\text{s.t.}\quad w_j\geq 0,\quad \mathbf{1}^{\top}w_j=1\ (j=1,2),\quad \Omega\succeq 0,\quad \operatorname{tr}(\Omega)=1.$$

- λ_1 约束权重整体幅度；λ_2 控制任务间信息共享的程度。Ω 衡量**任务关系**，而非资产收益协方差。

2．交替迭代求解

1. **初始化**：取 $\Omega^{(0)}=\frac{1}{2}I_2$，给定正则化参数 λ_1,λ_2。
2. **更新权重 W**：固定 Ω，求解带非负及预算约束的凸二次规划，得到 $W^{(k+1)}$。
3. **更新任务关系 Ω**：固定 W，使用解析更新式

$$\Omega^{(k+1)}=\frac{\left((W^{(k+1)})^{\top}W^{(k+1)}\right)^{1/2}}{\operatorname{tr}\left[\left((W^{(k+1)})^{\top}W^{(k+1)}\right)^{1/2}\right]}.$$

4. **重复至收敛**：输出两列权重 $\widehat{w}_{\mathrm{MV}}$（MTRL-MV）和 $\widehat{w}_{\mathrm{GMV}}$（MTRL-GMV）。

MTRL 的权重、任务关系与联合求解

一、W：同时估计两种投资规则的权重

令 $W=[w_1,w_2]$，其中 w_1 为 MV 权重、w_2 为 GMV 权重；两列均满足 $w_j\geq 0$、$\mathbf{1}^\top w_j=1$。

$$W=\begin{pmatrix}0.6 & 0.5\\ 0.3 & 0.3\\ 0.1 & 0.2\end{pmatrix},\qquad W^\top W=\begin{pmatrix}0.46 & 0.41\\ 0.41 & 0.38\end{pmatrix}$$

$W^\top W$ 的对角元表示各自的权重平方和，非对角元 $w_1^\top w_2$ 描述两组权重的交叉关系。

二、Ω 与关联惩罚：让两个任务在估计过程中相互影响

$\Omega\succeq 0$、$\mathrm{tr}(\Omega)=1$ 为待学习的任务关联矩阵。核心惩罚项为

$$P(W,\Omega)=\frac{\lambda_2}{2}\,\mathrm{tr}(W\Omega^{-1}W^\top)=\frac{\lambda_2}{2}\left(a\|w_1\|^2+b\|w_2\|^2+2c\,w_1^\top w_2\right),\quad \Omega^{-1}=\begin{pmatrix}a & c\\ c & b\end{pmatrix}.$$

若 $\Omega=\frac{1}{2}\begin{pmatrix}1 & \rho\\ \rho & 1\end{pmatrix}$，$0<\rho<1$，则

$$P(W,\Omega)=\frac{\lambda_2}{1-\rho^2}\left[(1-\rho)(\|w_1\|^2+\|w_2\|^2)+\rho\underbrace{\|w_1-w_2\|^2}_{\text{权重差异惩罚}}\right].$$

上例中 $\|w_1-w_2\|^2=(0.1)^2+0^2+(-0.1)^2=0.02$；$\rho>0$ 时，差异越大，关联惩罚越高。